

Aula 0: Revisão de Estatística

Silvio Costa

2025-08-12

1 Objetivo

Este documento contém uma revisão estatística selecionada para melhorar a introdução à econometria de séries de tempo e aos ambientes computacionais utilizados durante o curso. Não substitui a revisão individual do aluno sobre os conteúdos das disciplinas pré-requisitos.

2 Revisão de Estatística

2.1 Variáveis Aleatórias

Definição. Uma função X que atribui um número a cada resultado no espaço amostral Ω é uma variável aleatória. Variáveis aleatórias podem ser discretas ou contínuas.

- Discreta: assume valores finitos ou enumeráveis (ex: número de filhos).
- Contínua: assume qualquer valor em um intervalo $\mathbb{R}$ (ex: altura, renda)

Exemplos:

Considere o crescimento trimestral do PIB X . Podemos modelar X como uma variável contínua com distribuição aproximada Normal.

Outros exemplos?

2.2 Função de probabilidade (PF):

Para variável aleatória discreta, vale o conceito de função de probabilidade:

$$P(X = x)$$

Exemplo: Bernoulli, Binomial, Poisson

Algumas Distribuições Discretas:

Bernoulli: $X \in \{0, 1\}$

$$P(X = 1) = p, \quad P(X = 0) = 1 - p,$$

$$E[X] = p, \quad \text{Var}(X) = p(1 - p)$$

Binomial:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

$$E[X] = np, \quad \text{Var}(X) = np(1 - p).$$

Poisson:

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$$

$$E[X] = \lambda, \quad \text{Var}(X) = \lambda.$$

2.3 Função Densidade de Probabilidade (PDF)

Para variável contínua X com fdp $f(x)$:

$$P[a \leq X \leq b] = \int_a^b f(x) dx.$$

Exemplo: Normal, Exponencial

Algumas Distribuições Contínuas:

Exponencial:

$$P(X > t) = e^{-\lambda t}$$

$$E[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}$$

Normal:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2} \left(\frac{x - \mu}{\sigma}\right)^2\right\}$$

$$E[X] = \mu, \quad \text{Var}(X) = \sigma^2$$

2.4 Função de Distribuição Acumulada (CDF):

$$F(x) = P(X \leq x)$$

válida para qualquer tipo de variável aleatória.

2.5 Vetores Aleatórios

Sejam Y_1, Y_2 variáveis aleatórias; o par (Y_1, Y_2) é um vetor aleatório. Em séries temporais, muitas vezes as observações não são independentes e identicamente distribuídas (não-i.i.d.).

3 Esperança

O operador Esperança de uma variável aleatória X é definido como o valor esperado:

$$E[X] = \begin{cases} \sum_x x P(X = x), & X \text{ discreta,} \\ \int_{-\infty}^{\infty} x f(x) dx, & X \text{ contínua.} \end{cases}$$

Propriedades importantes:

- $E[aX + b] = aE[X] + b$
- $E[X + Y] = E[X] + E[Y]$
- $Var(X) = E[X^2] - [E[X]]^2$
- $Var(aX) = a^2 Var(X)$

Exemplo (R e Python): expectativa e variância do crescimento do PIB simulado

Hide

```
set.seed(2025)
n <- 100
pib_growth <- rnorm(n, mean = 0.01, sd = 0.02) # crescimento trimestral médio 1%
mean(pib_growth)
var(pib_growth)
hist(pib_growth, main = "Simulação: Crescimento do PIB (R)", xlab = "Taxa trimestral")
```

Hide

```
##% python
import numpy as np
import matplotlib.pyplot as plt
np.random.seed(2025)
n = 100
pib_growth = np.random.normal(0.01, 0.02, n)
print("Mean:", pib_growth.mean())
print("Var:", pib_growth.var(ddof=1))
plt.hist(pib_growth, bins=15)
plt.title("Simulação: Crescimento do PIB (Python)")
plt.xlabel("Taxa trimestral")
plt.show()
```

4 Esperança Condicional e Incondicional

Definição. A esperança condicional de Y dado X é $E[Y | X]$. A esperança incondicional satisfaz a regra:

$$E[Y] = E[E[Y | X]].$$

Exemplo:

Previsão da inflação π_t condicional à taxa Selic r_t : $E[\pi_t | r_t]$.

Em R e Python podemos estimar $E[\pi | r]$ por regressão linear simples (exemplo numérico simulado abaixo).

Hide

```
set.seed(1)
n <- 200
r <- rnorm(n, mean=0.08, sd=0.01) # taxa Selic simulada
pi <- 0.02 + 0.5*(r - 0.08) + rnorm(n, sd=0.005)
summary(lm(pi ~ r))
```

Hide

```
#%% python
import statsmodels.api as sm
import numpy as np
np.random.seed(1)
n = 200
r = np.random.normal(0.08, 0.01, n)
pi = 0.02 + 0.5*(r - 0.08) + np.random.normal(0, 0.005, n)
X = sm.add_constant(r)
model = sm.OLS(pi, X).fit()
print(model.summary())
```

5 Princípio da Máxima Verossimilhança (MLE)

Ideia. Dada uma amostra $x_1, \dots, x_n$ com densidade $f(x; \theta)$, a verossimilhança é

$$L(\theta; x) = \prod_{i=1}^n f(x_i; \theta),$$

e a log-verossimilhança $\ell(\theta) = \log L(\theta)$. O estimador de máxima verossimilhança (EMV) maximiza $\ell(\theta)$.

5.1 Exemplo: Bernoulli

Para n observações Bernoulli com k sucessos:

$$L(p) = p^k (1 - p)^{n-k}.$$

Maximizando, obtemos o EMV $\hat{p} = k/n$.

5.2 Exemplo: Exponencial

PDF exponencial (parâmetro α):

$$f(x; \alpha) = \frac{1}{\alpha} e^{-x/\alpha}, \quad x \geq 0.$$

Função Verossimilhança:

$$L(\alpha) = \alpha^{-n} \exp\left(-\frac{\sum_i x_i}{\alpha}\right),$$

Função log-verossimilhança:

$$\ell(\alpha) = -n \log \alpha - \frac{\sum_i x_i}{\alpha}.$$

Derivando e igualando a zero:

$$\hat{\alpha}_{MV} = \frac{1}{n} \sum_{i=1}^n x_i.$$

5.3 Estimação por MLE em R e Python (exponencial com dados simulados)

Suponha que X represente o tempo (em meses) até retorno a pleno emprego após choque — modelo exponencial.

[Hide](#)

```
set.seed(2025)
n <- 50
x <- rexp(n, rate = 1/0.5) # média 0.5 meses hipotética
negloglik <- function(alpha) {
  if (alpha <= 0) return(1e10)
  -(-n*log(alpha) - sum(x)/alpha)
}
res <- optim(par=0.5, fn=negloglik, method="Brent", lower=1e-6, upper=10)
res$par
# comparacao com media amostral
mean(x)
```

[Hide](#)

```
##% python
import numpy as np
from scipy import optimize
np.random.seed(2025)
n = 50
x = np.random.exponential(scale=0.5, size=n)
def negloglik(alpha):
    if alpha <= 0:
        return 1e10
    return -(-n*np.log(alpha) - x.sum()/alpha)
res = optimize.minimize_scalar(negloglik, bounds=(1e-6,10), method='bounded')
print("MLE alpha (scipy):", res.x)
print("Sample mean:", x.mean())
```

6 Critérios de Informação (AIC, BIC, HQ)

Considere um modelo com log-verossimilhança máxima $\ell_{\max}$ e k parâmetros.

- AIC:

$$\text{AIC} = -2\ell_{\max} + 2k.$$

- BIC:

$$\text{BIC} = -2\ell_{\max} + k \log(n).$$

- Hannan–Quinn (HQ):

$$\text{HQ} = -2\ell_{\max} + 2k \log(\log n).$$