

Aula 1: Fundamentos de Séries Temporais

Silvio Costa

2026-03-09

Plano

1. Introdução
 2. Classificação e Decomposição
-

(1) Introdução

Definições

- **O que é uma série temporal:** é uma coleção de dados ou variáveis obtidos em intervalos regulares ao longo do tempo.
 - Exemplos: podem ser intradiárias (preço de uma ação), diárias (taxa de juros Selic), mensais (inflação, desemprego, salário mínimo), trimestrais (PIB, renda disponível), anuais, etc...
- **Qual a importância da dimensão temporal?** Permite analisar e explicar as relações defasadas no tempo, aprender com momentos do passado e prever tendências econômicas e financeiras, algo essencial para tomada de boas decisões.

Objetivos de Estudar Séries Temporais


1. **Identificação de Padrões:** Detectar tendências, sazonalidades e ciclos nos dados para entender o comportamento histórico.
 2. **Previsão:** Estimar valores futuros com base em dados históricos.
 3. **Modelagem:** Desenvolver modelos que descrevem o comportamento dos dados, inclusive relações entre variáveis (multivariadas), permitindo simulações e decomposições.
 4. **Tomada de Decisão:** Informar decisões econômicas e financeiras com base em análises robustas e previsões que façam sentido.
 5. **Controle e Monitoramento:** Acompanhar e ajustar estratégias conforme mudanças nos dados, garantindo respostas rápidas diante de novas informações.
-

Exercício: obtendo séries temporais em APIs de bancos de dados públicos

```
# BANCO CENTRAL

dados_ipca = get_series(433, start_date = '2000-01-01')
ipca_ts = ts( dados_ipca$`433`, start = c( 2000, 1 ), frequency = 12 )      # IPCA
ts.plot(ipca_ts, xlab="Meses", ylab="p.p.", main = "IPCA - taxa mensal", col="red", lwd=2)
```


IPCA – taxa mensal



```
# BANCO CENTRAL
```

```
dados_pib = get_series(22099, start_date = '1995-01-01')
pib_ts = ts( dados_pib$`22099`, start = c( 1995, 1 ), frequency = 4 )      # IPCA
ts.plot(pib_ts, xlab="Trimestres", ylab="Índice", main = "PIB a preços de mercado (trimestral)", col="blue")
```

PIB a preços de mercado (trimestral)




```
library(zoo)

##
## Attaching package: 'zoo'
## The following objects are masked from 'package:base':
##
##   as.Date, as.Date.numeric
# pesquisar no site do ipeadata os códigos das séries que procura!

cambio = ipeadata("GM366_ERV366") # Taxa de câmbio
cambios = zoo( cambio$value, order.by=cambio$date )


plot(cambios, xlab="Dia", ylab="R$/US$", main = "Taxa de Câmbio diária", col="green")
```

Taxa de Câmbio diária



```
# selecione uma amostra mais recente, sem as mudanças de padrão monetário
cambios_rng = window(cambios, start = as.Date('2000-1-1'), end= Sys.Date() )
plot(cambios_rng, xlab="Dia", ylab="R$/US$", main = "Taxa de Câmbio diária", col="darkgreen")
```

Taxa de Câmbio diária




```
library(zoo)

dados_ibov = ipeadata("GM366_IBVSP366") # ibovespa
ibov_ts = zoo( dados_ibov$value, order.by=dados_ibov$date )

ibov_rng = window(ibov_ts, start = as.Date('2024-1-1'), end= Sys.Date())

plot(ibov_rng, xlab="Dia", ylab="índice", main = "Ibovespa diário", col="navy", lwd=2)
```

Ibovespa diário



Revisão de conceitos estatísticos básicos

- **Variável Aleatória:** Uma variável aleatória X pode assumir diferentes valores com certa probabilidade. Exemplo: $X \sim N(\mu, \sigma^2)$, onde μ é a média e σ^2 é a variância.
- **Vetores Aleatórios:** Um conjunto de variáveis aleatórias $X = (X_{\{1.\}}, X_{\{2.\}}, \dots, X_{\{n.\}})$, onde eventualmente cada X_i pode ter distribuições diferentes.
- **Distribuições de Probabilidade:** Funções que descrevem a probabilidade de diferentes resultados. Exemplo: Distribuição Normal $N(\mu, \sigma^2)$, Distribuição de Poisson $P(\lambda)$.
- **Máxima Verossimilhança:** método para estimar parâmetros Θ que maximizam a função de verossimilhança $L(\theta|X)$. Exemplo: Estimação de μ e σ na distribuição normal.
- **Critérios de Informação:** utilizamos para comparar modelos diferentes e escolher aqueles que tem melhor performance

- **Critério de Informação de Akaike (AIC):**

$$AIC = -2\log[L(\theta|X)] + 2K$$

- **Critério de Informação Bayesiano (BIC):**

$$BIC = -2\log[L(\theta|X)] + K\log(n)$$

Onde:

K é o número de parâmetros do modelo.

n é o tamanho da amostra.

O valor da função verossimilhança $L(\theta|X)$ é uma medida do ajuste de cada modelo aos dados.

(2) Classificação e Decomposição

- **Série Temporal:** Sequência de dados X_t ao longo do tempo.

Classificação

Processos Determinísticos e Estocásticos

- **Processos Determinísticos:** Processos onde os valores futuros são completamente determinados pelos valores presentes e passados, sem qualquer componente aleatório.

Exemplo: $X_t = a + b.t$, onde a e b são constantes.

- **Processos Estocásticos:** Processos onde os valores futuros dependem de valores presentes e passados, mas também incluem componentes aleatórios. Cada ponto no tempo é uma variável aleatória e a série estocástica é um conjunto de variáveis aleatórias.

Exemplo: $X_t = \phi X_{t-1} + \epsilon_t$, onde ϵ_t é um termo de erro aleatório.

Processos Estacionários e Não Estacionários

- **Definição:** Um processo é estacionário se suas propriedades estatísticas, como média, variância e autocorrelação, não mudam ao longo do tempo.

Exemplo: Séries temporais de retornos de ações ajustados para volatilidade.

- Importância da estacionariedade:
 - **Estabilidade:** Processos estacionários são estáveis ao longo do tempo, enquanto processos não estacionários não são.
 - **Previsibilidade:** Processos estacionários são mais previsíveis devido à manutenção de suas propriedades estatísticas.
 - **Transformações:** Processos não estacionários frequentemente precisam ser transformados para se tornarem estacionários antes da modelagem.
 - **Aplicação de Modelos:** Modelos univariados de séries temporais, como ARMA, assumem estacionariedade, tornando processos estacionários mais fáceis de modelar diretamente.
- **Tipos de Estacionariedade:**
 - Estacionariedade Forte/Estrita: Todas as propriedades estatísticas são constantes.

$$\mathcal{F}\left(\{\uparrow_{\square}\}_{\gamma=\infty}^{\parallel}\right) = \mathcal{F}\left(\{\uparrow_{\square}+\}_{\gamma=\infty}^{\parallel}\right), \forall \langle$$

- Estacionariedade (Frac): Apenas a média e covariâncias são constantes.

$$E[y] = \mu, \forall t E[y^2] < \infty E[(y_t - \mu)(y_{t-j} - \mu)] = \gamma_j$$



Decomposição de Séries Temporais

Séries de Natureza Econômica

$$Y_t = T_t + S_t + C_t + R_t$$


- **Tendência:** Movimento geral de longo prazo, indicando crescimento ou declínio. Exemplo: Aumento contínuo do PIB ao longo dos anos.
- **Sazonalidade:** Padrões que se repetem em intervalos regulares, como mensal ou anual. Exemplo: Vendas de varejo aumentam durante o período de festas.
- **Ciclo:** Flutuações econômicas de longo prazo, como ciclos de expansão e recessão. Exemplo: Ciclos de negócios que duram vários anos.
- **Componente Aleatório:** mudanças atípicas, eventos de curta duração e sem periodicidade.
- **Características:** Padrões e comportamentos específicos das séries econômicas, como estabilidade ou volatilidade. Pode ser aditivo ou multiplicativo.

use a função decompose() para obter uma decomposição de uma série temporal (usa filtragem)

```
decomp <-decompose(pib_ts, type = "multiplicative")
```

```
plot(decomp, col="blue" )
```


Decomposition of multiplicative time series




Séries de Natureza Financeira

- **Heterocedasticidade Condicional:** Variabilidade que muda ao longo do tempo, frequentemente modelada por GARCH. Exemplo: Volatilidade dos retornos de ações. Exemplo:

Daily Percentage Changes



- **Fraca Dependência Linear e Não Linear:** Relações fracas entre valores passados e futuros, podendo ser capturadas por modelos ARMA ou não lineares. Exemplo: Retornos de ativos financeiros que não seguem padrões previsíveis.
- **Caudas Pesadas:** Maior probabilidade de eventos extremos, como grandes perdas ou ganhos. Exemplo: Distribuição dos retornos de ações que mostra eventos extremos mais frequentes do que a distribuição normal.



- **Características:** Padrões e comportamentos específicos das séries financeiras, como alta volatilidade e eventos extremos.

Retornos de Ativos Financeiros

- **Retornos Simples:** Mudança percentual no valor de um ativo.

Fórmula: $R_t = \frac{(P_t - P_{t-1})}{P_{t-1}}$, onde P_t é o preço no tempo t e P_{t-1} é o preço no tempo anterior.

- **Retornos em Multiperíodos:** Retornos acumulados ao longo de vários períodos.

Fórmula: $R_{t \rightarrow (t+k)} = \prod_{i=0}^k (1 + R_{t+i}) - 1$, onde k é o número de períodos.

Exercício: comparar os retornos do IBOVESPA e do CDI em um determinado período de tempo

(1) coletar dados na API do IPEADATA

```
library(ipeadata)
library(xts)

# retornos: ret_IBOV, ret_CDI
dados_ibov = ipeadata("GM366_IBVSP366") # ibovespa
ibov_xts = xts( dados_ibov$value, order.by=dados_ibov$date )


dados_cdi = ipeadata("SGS366_CDI366") # cdi
cdi_xts = xts( dados_cdi$value, order.by=dados_cdi$date )
```

(2) selecionar janela temporal e visualizar dados


```
# filtro de datas
dataini = as.Date('2025-1-1')
datafim = as.Date('2026-2-27')

# recortar o intervalo desejado
ibov_win <- window(ibov_xts, start = dataini, end = datafim)
cdi_win <- window(cdi_xts, start = dataini, end = datafim)

plot(ibov_win, xlab="Dia", ylab="índice (pts)", main = "Ibovespa diário",
     col="navy", lwd=2, grid.col = "grey95"
)
```



```
plot(cdi_win, xlab="Dia", ylab="taxa ao dia (%)", main = "CDI diário",
     col="red", lwd=2, grid.col = "grey95"
)
```



```
ret_IBOV_TX_BRUTA = ibov_win / lag(ibov_win)
ret_CDI_TX_BRUTA = cdi_win/100 + 1

ret_IBOV_ACC = cumprod(na.omit(ret_IBOV_TX_BRUTA))
ret_CDI_ACC = cumprod(na.omit(ret_CDI_TX_BRUTA))

retornos_acc = merge(ret_IBOV_ACC, ret_CDI_ACC)

# assuma um investimento de 1000 reais na data inicial, veja a evolução do retorno até hoje
# use o pacote dygraph para um plot dinâmico

library(dygraphs)

dygraph(1000*retornos_acc, main = "Rentabilidade de R$ 1000") %>%
  dyRangeSelector() %>% # seletor de intervalo na parte de baixo
  dyOptions(drawGrid = TRUE) %>% # grade no fundo
  dyHighlight(highlightCircleSize = 5, highlightSeriesBackgroundAlpha = 0.2)
```