

Aula 2: Conceitos

Silvio Costa

2026-03-09

Plano

1. Funções Correlação(FC), Autocorrelação(FAC) e Autocorrelação Parcial (FACP)
 2. Ruído branco
 3. Teste de Ljung-box
-

(1) Funções características

Covariância vs. Correlação Assuma a seguinte equação:

$$y_t = \mu + \epsilon_t, \quad \epsilon_t \sim N(0, \sigma^2)$$

A autocovariância é a covariância entre a variável y_t no período t e a mesma variável em períodos do passado. Seja γ_j a autocovariância da série definida por:

\$\$

$$\begin{aligned}\gamma_j &= E[(y_t - \mu)(y_{t-j} - \mu)] \\ &= E(\epsilon_t \epsilon_{t-j})\end{aligned}$$

\$\$

Dadas as propriedades do ruído branco ϵ_t , a autovariância $\gamma_0 = \sigma^2$ e $\gamma_j = 0$ se $j \neq 0$.

Função Correlação (FC)

A função de correlação mede a relação linear entre duas variáveis. A correlação é uma medida estatística que indica a força e a direção da relação linear entre duas variáveis. É representada pelo coeficiente de correlação ρ , que varia entre -1 e 1.

Para duas variáveis X e Y :

$$\rho_{XY} = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

- $\rho = -1$: Indica uma correlação perfeita negativa, onde uma variável aumenta enquanto a outra diminui.
- $\rho = +1$: Indica uma correlação perfeita positiva, onde ambas as variáveis aumentam ou diminuem juntas.

- $\rho = 0$: Indica ausência de correlação linear entre as variáveis.

Exemplo: correlação entre os retornos do IBOVESPA e do CDI nos últimos 365 dias:

```
library(ipeadatar)
library(xts)

## Loading required package: zoo

##
## Attaching package: 'zoo'

## The following objects are masked from 'package:base':
##
##      as.Date, as.Date.numeric

# retornos: ret_IBOV, ret_CDI
dados_ibov = ipeadata("GM366_IBVSP366") # ibovespa
ibovxts = xts( dados_ibov$value, order.by=dados_ibov$date )

dados_cdi = ipeadata("SGS366_CDI366") # cdi
cdixts = xts( dados_cdi$value, order.by=dados_cdi$date )

ret_IBOV_TX_BRUTA = ibovxts / lag(ibovxts)
ret_CDI_TX_BRUTA = cdixts/100 + 1

retornos_brutos = merge(ret_IBOV_TX_BRUTA, ret_CDI_TX_BRUTA)
# janela de tempo
retornos_rng = window(retornos_brutos, start = Sys.Date()-365, end= Sys.Date() )

dados_sem_NA <- na.omit(retornos_rng) # remove datas que faltem em alguma série
correlacao_ibov_cdi <- cor(dados_sem_NA)
print(correlacao_ibov_cdi)

##                ret_IBOV_TX_BRUTA ret_CDI_TX_BRUTA
## ret_IBOV_TX_BRUTA          1.00000000      -0.06048016
## ret_CDI_TX_BRUTA          -0.06048016          1.00000000
```

Função Autocorrelação (FAC)

A autocorrelação mede a correlação de uma série temporal consigo mesma em diferentes momentos no tempo.

Para uma série X_t :

$$\rho_k = \frac{\text{cov}(X_t, X_{t+k})}{\sigma^2}$$

- **Autocorrelação positiva:** Indica que os valores da série temporal tendem a seguir na mesma direção. Por exemplo, se um valor é alto, os valores seguintes também tendem a ser altos.
- **Autocorrelação negativa:** Indica que os valores da série temporal tendem a seguir em direções opostas. Por exemplo, se um valor é alto, os valores seguintes tendem a ser baixos.
- **Autocorrelação próxima de zero:** Indica pouca ou nenhuma correlação entre os valores da série temporal em diferentes momentos.

Função Autocorrelação Parcial (FACP)

A autocorrelação parcial é uma extensão da autocorrelação que mede a correlação entre os valores de uma série temporal, eliminando a influência dos valores intermediários. Isso ajuda a identificar a relação direta em

diferentes lags.

Para uma série X_t :

$$\phi_k = \frac{\text{cov}(X_t, X_{t+k} | X_{t+1}, X_{t+2}, \dots, X_{t+k-1})}{\sigma^2}$$

- **PACF positiva:** Indica uma correlação direta positiva entre os valores da série temporal e o em diferentes lags, após ajustar para os valores intermediários.
- **PACF negativa:** Indica uma correlação direta negativa entre os valores da série temporal em diferentes lags, após ajustar para os valores intermediários.
- **PACF próxima de zero:** Indica pouca ou nenhuma correlação direta entre os valores da série temporal em diferentes lags, após ajustar para os valores intermediários.

A PACF pode ser calculada usando regressão múltipla.

$$X_t = \beta_0 + \beta_1 X_{t-1} + \beta_2 X_{t-2} + \beta_3 X_{t-3} + \dots + \beta_{k-1} X_{t-k-1} + \beta_k X_{t-k} + \epsilon_t$$

onde o coeficiente do lag X_{t-k} da regressão β_k é também o valor da PACF no lag k .

Exercício: calcular ACF e PACF para séries de tempo no R


```
library(rbcb)
# BANCO CENTRAL

tabela_ipca = get_series(433, start_date = '2000-01-01')
ipca_xts = xts( tabela_ipca$`433`, order.by = tabela_ipca$date` )      # IPCA

library(forecast)
par(mfrow=c(1,2))

# funcao acf também funciona, mas Acf do pacote forecast tem label mais bonito
vacf = forecast::Acf(ipca_xts, lag.max = 12, main="ACF IPCA mensal")

# funcao pacf também funciona, mas Pacf do pacote forecast tem label mais bonito
vpacf = forecast::Pacf(ipca_xts, lag.max = 12, , main="PACF IPCA mensal")
```



(2) Ruído branco

O processo estocástico $[\epsilon_t]_{t=0}^{\infty}$ é um ruído branco se:

1. $E(\epsilon_t) = 0, \forall t$
2. $E(\epsilon_t^2) = \sigma^2, \forall t$
3. $E(\epsilon_t, \epsilon_{t-j}) = 0, \forall j \neq 0$
 - Um ruído branco é simultaneamente: temporalmente homogêneo, estacionário e sem memória (sem dependência temporal).
 - Importante: a terceira propriedade de autocovariância nula não significa independência.

Criando um ruído branco no R a partir de uma distribuição normal:


```
set.seed(12345)

rb = rnorm(1000)

ts.plot(rb, lwd=2, xlab="tempo", col="blue", main="Ruído branco")

abline(h=0)
```

Ruído branco




```
rb2 = rnorm(1000, mean=0, sd=0.05)

ts.plot(rb2, main="Ruído branco com média 0 e desvio-padrão 0.05", xlab = "tempo", ylab="ruído(tempo)", col="blue", lty="n")


abline(h=c(0, -0.05, 0.05), lwd = 2, lty=c("solid", "dotted", "dotted"), col=c("black", "red", "red"))
```

Ruído branco com média 0 e desvio-padrão 0.05



Exercício: calcular as funções ACF e PACF para o ruído branco:

```
par(mfrow=c(1,2))  
  
vacf = acf(rb, lag.max = 12, main="ACF")  
  
vpacf = pacf(rb, lag.max = 12, , main="PACF")
```



Passeio aleatório

Se acumularmos o ruído branco ao longo do tempo, temos uma série especial chamada passeio aleatório.

Seja $y_{t=1}^T$ uma série dada por $y_t = y_{t-1} + \epsilon_t$, onde $\epsilon_t \sim RB(0, \sigma^2)$.

- Em passeio aleatório, o valor da série no instante t é o valor da série no instante anterior mais um erro de média zero, com variância constante.
- Recursivamente o passeio aleatório pode ser escrito como:

$$y_t = y_0 + \sum_{j=1}^t \epsilon_j$$


- O valor esperado, ou seja, a média y_t de em qualquer instante é igual ao valor y_0 (constante).
- A variância é dada por $var(y_t) = E(\sum_{j=1}^t \epsilon_j)^2 = t \cdot \sigma^2$ e aumenta com o tempo. Portanto, a série y_t não é estacionária.
- Tirando a primeira diferença do passeio aleatório, a série se torna um ruído branco, que é estacionário.
- Uma das características importantes do passeio aleatório é a persistência dos choques aleatórios (100%), isto é, o efeito de cada termo de erro não se “dissipa” ao longo do tempo. Logo, o passeio aleatório tem memória infinita, pois “guarda” a informação de todos os choques sofridos até o período corrente.

```
x_0 = 100

x_rw = x_0 + ts(cumsum(rb)) # random walk

ts.plot(x_rw, lwd=2, xlab="tempo", col="blue", main="Passeio aleatório")


abline(h=0)
```



```
par(mfrow=c(1,2))

vacf = acf(x_rw, lag.max = 12, main="ACF")

vpacf = pacf(x_rw, lag.max = 12, , main="PACF")
```



(3) Teste de Ljung-Box

Utilizado para verificar se as autocorrelações são conjuntamente identificadas e nulas.

Seja a hipótese nula:

$$H_0 : \rho_1 = \rho_2 = \dots = \rho_j = 0$$

$$H_A : \exists \rho_m \neq 0, \text{ para algum } m = 1, 2, \dots, j$$

Estatística do teste:

$$Q = T(T+2) \sum_{j=1}^n \frac{\rho_j^2}{T-j} \xrightarrow{d} \chi_n^2$$

onde $\xrightarrow{d}$ significa convergência em distribuição para uma qui-quadrada com n graus de liberdade.

Exemplo:

```
# Realizando o teste de Ljung-Box no ruído branco
teste_lb_rb <- Box.test(rb, lag = 10, type = "Ljung-Box")
print(teste_lb_rb)
```

```
##
## Box-Ljung test
##
```



```
## data:  rb
## X-squared = 8.8902, df = 10, p-value = 0.5426
# Realizando o teste de Ljung-Box no passeio aleatório
teste_lb_rw<- Box.test(x_rw, lag = 10, type = "Ljung-Box")
print(teste_lb_rw)

##
## Box-Ljung test
##
## data:  x_rw
## X-squared = 9556.5, df = 10, p-value < 2.2e-16
```