

Aula 3: Processos estacionários

Code ▼

Silvio Costa

21/mar/2025

Plano

1. Modelos MA
2. Modelos AR
3. Modelos ARMA

(1) Modelos MA (Moving Average)

- **Modelos MA (Médias Móveis):** Valor atual depende de erros passados. Fórmula:

$$MA(q) : \quad X_t = \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \dots + \theta_q \epsilon_{t-q}$$

Modelo MA(1)

A versão mais simples é um modelo MA de ordem 1. Temos:

$$y_t = \mu + \epsilon_t + \theta \epsilon_{t-1}$$

com $\epsilon_t \sim RB(0, \sigma^2)$.

- Como o ruído branco é estacionário, os modelos MA são também estacionários (combinação de ruídos brancos)
- Esperança:

$$E(y_t) = \mu + E(\epsilon_t) + \theta E(\epsilon_{t-1}) = \mu$$

- Variância:

$$\begin{aligned}
 \text{var}(y_t) &= E(y_t - \mu)^2 \\
 &= E(\epsilon_t + \theta\epsilon_{t-1})^2 \\
 &= E(\epsilon_t^2 + 2\theta\epsilon_t\epsilon_{t-1} + \theta^2\epsilon_{t-1}^2) \\
 &= E(\epsilon_t^2) + E(2\theta\epsilon_t\epsilon_{t-1}) + E(\theta^2\epsilon_{t-1}^2) \\
 &= \sigma^2 + 0 + \theta^2\sigma^2 \\
 &= (1 + \theta^2)\sigma^2
 \end{aligned}$$

- Autocovariância:

$$\begin{aligned}
 E[(y_t - \mu)(y_{t-1} - \mu)] &= E[(\epsilon_t + \theta\epsilon_{t-1})(\epsilon_{t-1} + \theta\epsilon_{t-2})] \\
 &= E[\epsilon_t\epsilon_{t-1} + \theta\epsilon_t\epsilon_{t-2} + \theta\epsilon_{t-1}^2 + \theta^2\epsilon_{t-1}\epsilon_{t-2}] \\
 \gamma_1 &= \theta\sigma^2
 \end{aligned}$$

Exercício: crie um modelo MA(1) e calcule as suas funções ACF e PACF. Faça o teste de Ljung-Box e explique os resultados.

Hide

```
# Definindo o coeficiente MA e o número de observações
ma_coef <- 0.1
n <- 1000


# Gerando ruído branco
set.seed(1234)
ruído_branco <- rnorm(n)

# Inicializando o vetor do processo MA(1)
ma_process <- numeric(n)

# Calculando os valores do processo MA(1) em um loop
for (t in 2:n) {
  ma_process[t] <- ruído_branco[t] + ma_coef * ruído_branco[t-1]
}

# Visualizando MA(1)
plot(ma_process, type = "l", main = "Processo MA(1)", ylab = "Valores", xlab = "Tempo")
```


Processo MA(1)




Hide

```
par(mfrow=c(1,2))  
  
vacf = acf(ma_process, lag.max = 12, main="ACF")  
  
vpacf = pacf(ma_process, lag.max =12, main="PACF")
```

ACF



PACF



Hide

```
teste_lb_ma_process <- Box.test(ma_process, lag = 12, type = "Ljung-Box")
print(teste_lb_ma_process)
```

Box-Ljung test

data: ma_process

X-squared = 19.605, df = 12, p-value = 0.07494

- Podemos generalizar os modelos de médias móveis pela seguinte equação:

$$MA(q) : y_t = \mu + \sum_{j=0}^q \theta_j \epsilon_{t-j}, \quad \theta_0 = 1$$

- A partir da defasagem q , a autocorreção desaparece, o que permite identificar a ordem do processo MA.

Exercício: Seja um MA(2), calcule $E[y_t]$, $var[y_t]$ e as autocovariâncias e autocorrelações.

(2) Modelos AR (Auto Regressive)

- **Modelos AR (Auto-Regressivos):** Valor atual depende de valores passados. Fórmula:

$$AR(p) : X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p} + \epsilon_t$$

- Os processos auto-regressivos (AR) são compostos por uma variável dependente X_t e um termo de erro que é um ruído branco ϵ_t .

Modelo AR(1)

A versão mais simples é o modelo de ordem 1. Temos:

$$y_t = c + \phi y_{t-1} + \epsilon_t, \quad \epsilon_t \sim RB(0, \sigma^2)$$

- Sob que condições o modelo AR(1) é estacionário?
- Assumimos $|\phi| < 1$ como condição de estabilidade. Por que?

- Para verificar as condições de estabilidade, é mais fácil manipular o modelo AR mediante substituições recursivas para incluir termos de ruído branco, os quais conhecemos as propriedades. Então:

$$(1 - \phi L)y_t = c + \epsilon_t$$

$$y_t = \frac{c}{1 - \phi} + \sum_{j=0}^{\infty} \phi^j \epsilon_{t-j}$$

- Logo, assumindo estabilidade, o modelo AR(1) pode ser escrito como um modelo MA(∞)
- Esperança:

$$E(y_t) = \frac{c}{1 - \phi} = \mu$$

- Variância:

$$\begin{aligned} \text{var}(y_t) &= E(y_t - \mu)^2 \\ &= E\left(\sum_{j=0}^{\infty} \phi^j \epsilon_{t-j}\right)^2 \\ &= E\left(\sum_{j=0}^{\infty} \phi^{2j} \epsilon_{t-j}^2\right) \\ &= E(\epsilon_t^2) + \phi^2 E(\epsilon_{t-1}^2) + \phi^4 E(\epsilon_{t-2}^2) + \dots \\ &= \sigma^2 + \phi^2 \sigma^2 + \phi^4 \sigma^2 + \dots \\ &= \frac{\sigma^2}{1 - \phi^2} \end{aligned}$$

- Autocovariância:

$$\begin{aligned} E[(y_t - \mu)(y_{t-j} - \mu)] &= E\left[\left(\sum_{s=0}^{\infty} \phi^s \epsilon_{t-s}\right)\left(\sum_{s=0}^{\infty} \phi^s \epsilon_{t-s-j}\right)\right] \\ &= \phi^j \sigma^2 + \phi^{j+2} \sigma^2 + \phi^{j+4} \sigma^2 + \dots \\ &= \sigma^2 (\phi^j + \phi^{j+2} + \phi^{j+4} + \dots) \\ \gamma_j &= \left(\frac{\phi^j}{1 - \phi^2}\right) \sigma^2 \end{aligned}$$

- Autocorrelações:

$$\rho_j = \phi^j$$

- Média, variância e autocovariâncias não são funções do tempo, então o processo é fracamente estacionário!

Modelo AR(2)

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \epsilon_t, \quad \epsilon_t \sim RB(0, \sigma^2)$$

- Esperança:

$$\begin{aligned} E(y_t) &= c + \phi_1 E(y_{t-1}) + \phi_2 E(y_{t-2}) + E(\epsilon_t) \\ &= \frac{c}{1 - \phi_1 - \phi_2} = \mu \end{aligned}$$

- Parece haver uma regularidade quando comparado ao AR(1)
- Vamos generalizar a expressão, centrando o AR(2) na média μ e tomar a esperança:

$$(y_t - \mu) = \phi_1 (y_{t-1} - \mu) + \phi_2 (y_{t-2} - \mu) + \epsilon_t$$

- As autocovariâncias são dadas por:

$$\begin{aligned} E[(y_t - \mu)(y_{t-j} - \mu)] &= \phi_1 E[(y_{t-1} - \mu)(y_{t-j} - \mu)] + \phi_2 E[(y_{t-2} - \mu)(y_{t-j} - \mu)] \\ \gamma_j &= \phi_1 \gamma_{j-1} + \phi_2 \gamma_{j-2} \quad j = 1, 2, 3 \dots \end{aligned}$$

- Logo, as autocovariâncias e autocorrelações seguem um processo autorregressivo de ordem 2:

$$\begin{aligned} \gamma_j &= \phi_1 \gamma_{j-1} + \phi_2 \gamma_{j-2} \\ \rho_j &= \phi_1 \rho_{j-1} + \phi_2 \rho_{j-2} \end{aligned}$$

- Essas equações são conhecidas como “equações de Yule-Walker”. São interessantes pois permitem verificar a função de autocorrelação do processo.
- A generalização do AR para ordem p é dada por:

$$y_t = c + \sum_{j=1}^p \phi_j y_{t-j} + \epsilon_t$$

- Utilizando o operador defasagem podemos escrever

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p) y_t = c + \epsilon_t$$

- Se o termo entre parênteses for inversível, podemos escrever o modelo AR(p) como um modelo MA(∞). Isso será verdade se as raízes da equação $(1 - \phi_1 z - \phi_2 z^2 - \dots - \phi_p z^p) > 0$, ou seja, se as raízes estiverem fora do círculo unitário.

Exemplo: como simular um modelo AR(p)

Hide


```
# Definir os coeficientes do modelo AR(p)
p <- 2
ar_coef <- c(1.3, -0.5) # Coeficientes AR

# Número de observações
n <- 100

# Simular a série temporal AR(p)
set.seed(123) # Para reprodutibilidade
ar2_sim <- arima.sim(model = list(ar = ar_coef), n = n)

plot(ar2_sim, main = "Série Temporal Simulada AR(2)")
```


Série Temporal Simulada AR(2)




Hide

```
par(mfrow=c(1,2))  
  
vacf = acf(ar2_sim, lag.max = 12, main="ACF")  
  
vpacf = pacf(ar2_sim, lag.max = 12 , main="PACF")
```

ACF



PACF



Exemplo: como verificar se um modelo AR ajustado aos dados é estável?

Hide

```
# Exemplo de dados
dados <- c(1.2, 2.4, 3.1, 4.5, 5.7, 6.8, 7.9, 8.3, 9.1, 10.5)

# Ajustar um modelo AR(p) com ordem p = 2
modelo_ar <- arima(dados, order = c(2, 0, 0))

# Obter os coeficientes do modelo
coeficientes <- coef(modelo_ar)
print(coeficientes)
```

```
      ar1      ar2 intercept
1.8632569 -0.8893384  6.3242943
```

Hide

```
# Calcular as raízes do polinômio característico
polinomio <- c(1, -coeficientes[1:2])
raizes <- polyroot(polinomio)

print(raizes)
```

```
[1] 1.047552+0.1645166i 1.047552-0.1645166i
```


Hide

```
# Plotar o círculo unitário
plot(0, 0, type = "n", xlab = "Parte Real", ylab = "Parte Imaginária",
     xlim = c(-1.5, 1.5), ylim = c(-1.5, 1.5), asp = 1)
symbols(0, 0, circles = 1, inches = FALSE, add = TRUE)
```

Hide

```
# Plotar as raízes
points(Re(raizes), Im(raizes), col = "red", pch = 19)

# Adicionar título
title("Raízes do Polinômio Característico no Círculo Unitário")
```



```
# Verificar se as raízes estão fora do círculo unitário
estabilidade <- all(Mod(raizes) > 1)
print(estabilidade)
```

```
[1] TRUE
```

(3) Modelos ARMA

Combinando as expressões de AR(p) e MA(q) temos:

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \sum_{j=0}^q \theta_j \epsilon_{t-j}$$

- Esperança:

$$E(y_t) = \frac{c}{1 - \sum_{i=1}^p \phi_i} = \mu$$

- Outra forma de escrever o processo ARMA, considerando a média incondicional μ :

$$y_t = \mu + \sum_{i=1}^p \phi_i (L^i y_t - \mu) + \sum_{j=0}^q L^j \theta_j \epsilon_t$$

$$y_t = \mu + \frac{1 + \sum_{j=0}^q L^j \theta_j}{1 - \sum_{i=1}^p \phi_i L^i} \epsilon_t$$

$$y_t = \mu + \psi(L) \epsilon_t$$

- As autocovariâncias são construídas de forma similar ao que fizemos para o AR(2): encontramos $(y_t - \mu)$ e tomamos o operador esperança. Substituindo o valor da média na equação do processo:

$$(y_t - \mu) = \sum_{i=1}^p \phi_i (y_{t-i} - \mu) + \sum_{j=0}^q \theta_j \epsilon_{t-j}$$

$$(y_t - \mu) = \psi(L) \epsilon_t$$

- Para uma autocovariância de ordem h maior do que a ordem q do processo MA, vale $E[\epsilon_{t-j}(y_{t-h} - \mu)] = 0$. Então podemos encontrar um processo autorregressivo de ordem p :

$$\gamma_h = \phi_1 \gamma_{h-1} + \phi_2 \gamma_{h-2} + \dots + \phi_p \gamma_{h-p}, \quad h = q+1, q+2, q+3, \dots$$

- Quando $h \leq q$, as funções de autocovariâncias se tornam complicadas pois $E[\epsilon_{t-j}(y_{t-h} - \mu)] \neq 0$.
- Por isso, vamos trabalhar com funções de autocovariância/autocorrelação que são maiores do que a ordem do processo MA.
- Importante: para estimar modelos ARMA(p,q) é preciso que eles sejam estáveis. Isso significa que as raízes das equações características dos processos AR(p) e MA(q) devem estar simultaneamente fora do círculo unitário!!!!

Exemplo: Vamos simular um modelo ARMA(2,2) no R.

Hide


```
# Definir os coeficientes do modelo AR(p)
p <- 2
ar_coef <- c(1.3, -0.5) # Coeficientes AR
q <- 2
ma_coef <- c(0.9, 0.3)  # Coeficientes MA

# Número de observações
n <- 1000

# Simular a série temporal AR(p)
set.seed(123) # Para reprodutibilidade
arma_sim <- arima.sim(model = list(ar = ar_coef, ma = ma_coef), n = n)

plot(arma_sim, main = "Série Temporal Simulada ARMA(2,2)")
```

Série Temporal Simulada ARMA(2,2)



Vamos verificar se as raízes do processo estão fora do círculo unitário. Precisamos verificar as raízes da parte AR e da parte MA.

Hide

```
# Calcular as raízes dos polinômios característicos
polinomio_ar <- c(1, -ar_coef)
raizes_ar <- polyroot(polinomio_ar)

polinomio_ma <- c(1, +ma_coef)
raizes_ma <- polyroot(polinomio_ma)

print(c(raizes_ar, raizes_ma))
```

```
[1] 1.3+0.5567764i 1.3-0.5567764i -1.5+1.0408330i -1.5-1.0408330i
```

Hide

```
# Plotar o círculo unitário
plot(0, 0, type = "n", xlab = "Parte Real", ylab = "Parte Imaginária",
     xlim = c(-1.5, 1.5), ylim = c(-1.5, 1.5), asp = 1)
symbols(0, 0, circles = 1, inches = FALSE, add = TRUE)
```


Hide

```
# Plotar as raízes
points(Re(raizes_ar), Im(raizes_ar), col = "red", pch = 19)
points(Re(raizes_ma), Im(raizes_ma), col = "orange", pch = 19)
```

Hide

```
# Adicionar título
title("Raízes do Polinômio Característico no Círculo Unitário")
```

Raízes do Polinômio Característico no Círculo Unitário




Então, se todas as raízes estão fora do círculo unitário, o modelo ARMA é estável. Vamos calcular as funções de autocorrelação:

Hide

```
par(mfrow=c(1,2))  
  
vacf = acf(arma_sim, lag.max = 12, main="ACF")  
  
vpacf = pacf(arma_sim, lag.max = 12 , main="PACF")
```

ACF



PACF

