

Aula 4: Estimação de modelos ARIMA

Silvio Costa

11/abr/2025

Plano

- Revisar o conceito de máxima verossimilhança (MV)
 - Entender a diferença entre verossimilhança exata e aproximada
 - Aplicar o conceito a um modelo AR(1)
 - Usar **R** para estimar os parâmetros
-

1. Máxima Verossimilhança: Revisão

Os pacotes estatísticos como o R possibilitam simular e estimar os coeficientes de modelos de séries temporais.

Vamos retomar o conceito de máxima verossimilhança e como aplicá-la nos modelos ARMA(p,q).

Dado um vetor de dados $Y = (y_1, \dots, y_T)$ e um vetor de parâmetros θ , a função de verossimilhança é:

$$L(\theta|y) = f(y_1, y_2, \dots, y_T | \theta)$$

A log-verossimilhança é:

$$\ell(\theta|y) = \log L(\theta|y)$$

Queremos estimar:

$$\hat{\theta}_{MV} = \arg \max_{\theta} \ell(\theta)$$

Em particular, usamos a distribuição normal como hipótese para a distribuição dos erros dos modelos em séries econômicas e financeiras:

$$L(\beta, \sigma^2|y) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(y_i - \beta x_i)^2}{2\sigma^2}\right]$$

$$\ell(\beta, \sigma^2|y) = n \cdot \ln\left[\frac{1}{\sqrt{2\pi\sigma^2}}\right] - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta x_i)^2$$

2. Verossimilhança Aproximada (Condicional)

Adaptando ao modelo de séries temporais, a ideia da estimação é usar as p primeiras observações como valores iniciais para maximizar a função de verossimilhança (condicional):

$$\ell(\theta|y) = \frac{T-p}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_t - c - \sum_{i=1}^p \phi^i y_{t-i})^2$$

Os estimadores são obtidos ao tomar as condições de primeira ordem com relação a c , ϕ_i e σ^2 e igualá-las a zero.

A verossimilhança condicional ou aproximada ignora a distribuição das observações iniciais (y_1 por exemplo) e considera apenas as distribuições a posteriori:

$$L_c(\phi, \sigma^2) = \prod_{t=2}^T f(y_t | y_{t-1})$$

Vantagem: Mais simples, boa aproximação quando T é grande e é flexível para o caso de séries não estacionárias.

As máximas verossimilhanças condicional e exata têm as mesmas propriedades assintóticas quando o modelo é estacionário (raízes fora do círculo unitário).

A estimação de ϕ_i por máxima verossimilhança condicional é equivalente ao método de mínimos quadrados ordinários. No entanto, o estimador da variância não é igual ao de mínimos quadrados.

3. Verossimilhança Exata

Precisamos conhecer a distribuição incondicional do processo y_t e assumir que as primeiras observações ou são determinadas ou seguem a distribuição incondicional.

No caso de um modelo AR(1):

$$y_t = \phi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2)$$

Para calcular a verossimilhança, precisamos assumir $|\phi| < 1$ (estacionariedade) para definir a distribuição incondicional e assumir que y_1 segue a distribuição incondicional.

$$y_1 \sim \mathcal{N}(0, \frac{\sigma^2}{1 - \phi^2})$$

A função de verossimilhança é:

$$L(\phi, \sigma^2) = f(y_1) \prod_{t=2}^T f(y_t | y_{t-1})$$

Vantagens: Estimativa eficiente, porém requer estacionariedade.

4. Comparação dos Métodos

Critério	Exata	Aproximada
Precisão	Alta	Boa se T grande
Complexidade	Maior	Menor
Exige estacionariedade	Sim	Não necessariamente
Método no software R	method = "ML"	method = "CSS"

5. Exemplo no R: simulação de série AR(1)


```
set.seed(12345)
T <- 200
phi <- 0.7
sigma <- 1
y <- numeric(T)

# Condição inicial para estacionariedade
y[1] <- rnorm(1, 0, sqrt(sigma^2 / (1 - phi^2)))

# Gerando a série
for (t in 2:T) {
  y[t] <- phi * y[t-1] + rnorm(1, 0, sigma)
}

ts.plot(y, main = "Série AR(1) Simulada", ylab = "y_t")
```

Série AR(1) Simulada



6. Estimação do modelo simulado

```
model_approx <- arima(y, order = c(1, 0, 0), method = "CSS",
                      include.mean = FALSE, n.cond= 10)

model_exact <- arima(y, order = c(1, 0, 0), method = "ML",
                    include.mean = FALSE)
```

Compare os resultados: estimativas dos coeficientes ϕ , variâncias, Log-verossimilhança, AIC

```
model_approx
```

```
##
## Call:
## arima(x = y, order = c(1, 0, 0), include.mean = FALSE, method = "CSS", n.cond = 10)
##
## Coefficients:
##          ar1
##         0.7027
## s.e.   0.0501
##
## sigma^2 estimated as 1.181:  part log likelihood = -300.4
```

```
model_exact
```

```
##
## Call:
## arima(x = y, order = c(1, 0, 0), include.mean = FALSE, method = "ML")
##
## Coefficients:
##          ar1
##         0.6978
## s.e.   0.0501
##
## sigma^2 estimated as 1.152:  log likelihood = -298.31,  aic = 600.61
```