

Aula 6: Sazonalidade e Suavização

Silvio Costa

2025-04-26

Plano

- Aprender a identificar e ajustar a sazonalidade em séries temporais.
- Implementar o ajuste de sazonalidade por médias móveis.
- Implementar o ajuste de sazonalidade utilizando R.

Motivação

- Na abordagem tradicional, as séries de tempo são ajustadas por algoritmos determinísticos.
- Intuição: expurgar fatores que geram perturbações na série e ter uma noção mais precisa da sua trajetória.
- Dentre os algoritmos de suavização para filtrar a sazonalidade de séries temporais, vamos explorar o uso de médias móveis.

Média Móvel Tradicional

Definição

- O modelo de média móvel tradicional assume que o processo é produto de quatro fatores:

$$y_t = C_t \times S_t \times T_t \times U_t$$

onde:

C_t : componente de ciclo de longo prazo

S_t : componente sazonal

T_t : componente de tendência

U_t : componente irregular

- A abordagem mais básica utiliza médias móveis tradicionais para estimar e expurgar S_t .
- Hipótese subjacente: componente sazonal é fixo para subperíodos iguais.

Estimação

- Para o caso de séries mensais e trimestrais, calculamos a média móvel centrada:

$$x_t = \frac{0,5y_{t-6} + y_{t-5} + \dots + y_{t+5} + 0,5y_{t+6}}{12}$$

$$x_t = \frac{0,5y_{t-2} + y_{t-1} + y_t + y_{t+1} + 0,5y_{t+2}}{4}$$

- O filtro de médias móveis tradicional elimina os componentes de sazonalidade (S_t) e irregular (U_t).

- Nesse caso, podemos reescrever $x_t = C_t \times T_t$. Assim, vamos fazer a seguinte manipulação algébrica:

$$z_t \equiv \frac{y_t}{x_t} = \frac{C_t \times S_t \times U_t \times T_t}{C_t \times T_t} = S_t \times U_t$$

- Intuição: ao dividir a série original pela média móvel, obtemos os componentes de sazonalidade (S_t) e irregular (U_t).

Estimação

- O próximo passo é isolar os termos sazonais do componente irregular.
- Faremos isso calculando a média de cada subperíodo de z_t (por exemplo, se a periodicidade da série for mensal, calcularemos as médias de janeiro, fevereiro, etc.).
- Estas médias serão dadas por:

$$\bar{v}_j = \frac{\sum_{m=0}^{T-j} z_{mq+j}}{T-j+1}, j = 1, 2, \dots, q$$

Em que q representa um número inteiro dentre os subperíodos da série temporal.

- Por fim, normalizamos os índices sazonais pela média geométrica:

$$v_j = \frac{\bar{v}_j}{\sqrt[q]{\prod_{j=1}^q \bar{v}_j}}$$

- A normalização nos fornece uma medida relativa do padrão sazonal, permitindo verificar quanto a série original se difere da série dessazonalizada.
- O passo final é dividir a série de tempo original y_t pelo índice de sazonalidade correspondente ao mês t :

$$SA_{mq+j} = \frac{y_{mq+j}}{v_j}$$

Exercício: calcular os fatores sazonais do IPCA

E se os fatores sazonais não forem determinísticos????

#

Sazonalidade usando a metodologia ARIMA

A metodologia ARIMA (AutoRegressive Integrated Moving Average) é uma das técnicas mais utilizadas para modelagem de séries temporais.

Quando lidamos com séries temporais que apresentam padrões sazonais, utilizamos uma extensão chamada SARIMA (Seasonal ARIMA).

Conceitos Básicos

Modelos ARIMA

Os modelos ARIMA são definidos por três parâmetros: p, d, q:

- **p**: ordem da parte autoregressiva (AR).

- **d**: grau de diferenciação necessário para tornar a série estacionária.
- **q**: ordem da parte de média móvel (MA).

Modelos SARIMA

Os modelos SARIMA incluem componentes sazonais e são definidos por sete parâmetros: p , d , q , P , D , Q , m :

- **P**: ordem da parte autoregressiva sazonal.
- **D**: grau de diferenciação sazonal.
- **Q**: ordem da parte de média móvel sazonal.
- **m**: período sazonal (por exemplo, 12 se dados mensais).

Identificação da Sazonalidade

Para identificar a sazonalidade em uma série temporal, podemos utilizar a decomposição da série em seus componentes: tendência, sazonalidade e resíduo. A visualização gráfica é uma ferramenta poderosa para identificar padrões sazonais.

Implementação em R

Vamos implementar um exemplo de ajuste de sazonalidade utilizando a metodologia SARIMA em R.

```
# Carregar pacotes necessários
library(rbc)
library(forecast)


## Registered S3 method overwritten by 'quantmod':
##   method      from
##   as.zoo.data.frame zoo

library(tseries)

# Exemplo de série temporal
set.seed(123)


# BANCO CENTRAL
data.ipca = get_series(433, start_date = '2000-01-01')
ipca_serie_temporal = ts( data.ipca$`433`, start = c( 2000, 1 ), frequency = 12 )      # IPCA
ts.plot(ipca_serie_temporal, xlab="Meses", ylab="p.p.", main = "IPCA - taxa mensal", col="red", lwd=2)
```

IPCA – taxa mensal



```
# Decomposição da série temporal  
decomposicao <- decompose(ipca_serie_temporal)  
plot(decomposicao)
```

Decomposition of additive time series



```

# Ajuste do modelo SARIMA
modelo_sarima <- auto.arima(ipca_serie_temporal, seasonal = TRUE)


# Resumo do modelo
summary(modelo_sarima)

## Series: ipca_serie_temporal
## ARIMA(1,0,0)(1,0,1)[12] with non-zero mean
##
## Coefficients:
##          ar1      sar1      sma1      mean
##          0.6090  0.8822 -0.7549  0.5087
## s.e.    0.0454  0.0795   0.1058  0.0805
##
## sigma^2 = 0.09546: log likelihood = -73.22
## AIC=156.43   AICc=156.63   BIC=175
##
## Training set error measures:
##              ME      RMSE      MAE  MPE  MAPE      MASE      ACF1
## Training set -0.003778702 0.3069175 0.2133396 -Inf  Inf  0.6094819 -0.00648454

# Previsão utilizando o modelo SARIMA
previsao <- forecast(modelo_sarima, h = 12)
plot(previsao, main = "Previsão com Modelo SARIMA")

```

Previsão com Modelo SARIMA




```

# Avaliação do ajuste sazonal
checkresiduals(modelo_sarima)

```

Residuals from ARIMA(1,0,0)(1,0,1)[12] with non-zero mean



```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(1,0,0)(1,0,1)[12] with non-zero mean
## Q* = 15.546, df = 21, p-value = 0.7946
##
## Model df: 3.    Total lags used: 24
```