

Aula 7: Exercício Dirigido: Modelagem do IBC-BR com Box-Jenkins

Silvio Costa

2025-04-26

Introdução & Contextualização

Nesta aula, aplicaremos a metodologia Box-Jenkins para modelar a série temporal do IBC-BR utilizando técnicas de análise gráfica, testes econométricos e estimação de modelos ARIMA. Nosso enfoque inclui:

- **Compreender a Metodologia Box-Jenkins:** Explorar o ciclo de identificação, estimação, diagnóstico e previsão de modelos ARIMA.
- **Realizar Análise Gráfica e Econométrica:** Visualizar os dados do IBC-BR, identificar seus componentes (tendência, sazonalidade e irregularidade) e testar sua estacionaridade.
- **Explorar Especificações Manuais com Grid Search:** Testar diversas combinações dos parâmetros p (autoregressivo) e q (média móvel) em um ambiente controlado antes de recorrer ao `auto.arima()`.
- **Estimar, Diagnosticar e Prever:** Selecionar o melhor modelo com base em critérios informacionais (AIC/BIC), avaliar os resíduos e gerar previsões futuras.

Motivação econômica

- O IBC-BR (Índice de Atividade Econômica do Banco Central) é um indicador econômico criado pelo Banco Central do Brasil. Ele tem como objetivo acompanhar a evolução da atividade econômica do país, funcionando como uma espécie de “prévia” do PIB (Produto Interno Bruto).
- Principais Características do IBC-BR:
 - Periodicidade Mensal: Diferente do PIB, que é divulgado trimestralmente, o IBC-BR é calculado e divulgado mensalmente, permitindo um diagnóstico mais rápido da economia
 - Componentes: O índice considera dados de diversos setores, como indústria, comércio varejista, agropecuária e serviços.

Análise Exploratória e Gráfica

Nesta etapa, vamos carregar os dados do IBC-BR e realizar a análise gráfica da série.

```
# Carregando os pacotes necessários
library(rbcbr)
library(forecast) # Modelos ARIMA e forecast
```


```
## Registered S3 method overwritten by 'quantmod':
##   method      from
##   as.zoo.data.frame zoo
```

```
library(tseries)      # Teste de raiz unitária (ADF)
library(ggplot2)      # Visualizações
```

Carregando os dados – neste exemplo, buscamos os dados diretamente no repositório do Banco Central:


```
data.ibcbr <- get_series(24364, start_date = '2003-01-01')
IBC_BR <- ts(data.ibcbr$`24364`, start = c(2003, 1), frequency = 12)    # IBC-BR

# Plot da série do IBC-BR
autoplot(IBC_BR) +
  ggtitle("Série do IBC-BR") +
  xlab("Tempo") +
  ylab("IBC-BR")
```



Podemos utilizar uma função de decomposição da série para destacar tendência, sazonalidade e componente irregular:


```
decomp <- decompose(IBC_BR)
autoplot(decomp) +
  ggtitle("Decomposição da Série do IBC-BR")
```



Verificação de Estacionaridade e Diferenciação

- A estacionaridade é essencial para a modelagem Box-Jenkins, que consiste na estimação (data fitting) de modelos da família ARIMA.
- A série do IBC-BR não é estacionária, pois tem tendência (veremos depois como testar e tratar mais precisamente).
- Por enquanto, aplicamos a primeira diferenciação e visualizamos o resultado:

```
IBC_BR_diff <- diff(log(IBC_BR))
autoplot(IBC_BR_diff) +
  ggtitle("Série do IBC-BR após Primeira Diferenciação") +
  xlab("Tempo") +
  ylab("Tx crescimento IBC-BR")
```



- Vamos agora testar se a série diferenciada é estacionária:

```
# Teste de Dickey-Fuller
adf_test <- adf.test(IBC_BR_diff)

## Warning in adf.test(IBC_BR_diff): p-value smaller than printed p-value

# Teste Phillips-Perron
pp_test <- pp.test(IBC_BR_diff)

## Warning in pp.test(IBC_BR_diff): p-value smaller than printed p-value

# Teste KPSS
kpss_test <- kpss.test(IBC_BR_diff)

## Warning in kpss.test(IBC_BR_diff): p-value greater than printed p-value

# Exibir os resultados dos testes
print(adf_test)

##
## Augmented Dickey-Fuller Test
##
## data: IBC_BR_diff
## Dickey-Fuller = -6.9537, Lag order = 6, p-value = 0.01
## alternative hypothesis: stationary
print(pp_test)

##
## Phillips-Perron Unit Root Test
```

```
##
## data: IBC_BR_diff
## Dickey-Fuller Z(alpha) = -192.18, Truncation lag parameter = 5, p-value
## = 0.01
## alternative hypothesis: stationary
```

```
print(kpss_test)
```

```
##
## KPSS Test for Level Stationarity
##
## data: IBC_BR_diff
## KPSS Level = 0.22791, Truncation lag parameter = 5, p-value = 0.1
```

Qual a conclusão?


Metodologia Box-Jenkins: Grid Search

- Os softwares econométricos têm pacotes que facilitam encontrar o melhor ajuste dos dados para dezenas de combinações de modelos da família ARIMA.
- Todavia, antes de utilizar o `auto.arima()` do R, vamos explorar como fazer isso manualmente (o resultado automático nem sempre é o melhor!!)

Correlograma da série de IBC-BR com 1 diferenciação:

```
par(mfrow=c(1,2))

vacf <- acf(IBC_BR_diff, lag.max = 12, main="ACF")
vpacf <- pacf(IBC_BR_diff, lag.max = 12, main="PACF")
```



A partir da análise do correlograma da série, exploramos diferentes combinações dos parâmetros p e q (variando de 0 a 3) e compararemos os modelos com base nos critérios AIC e BIC.

```
# Definindo intervalos para os parâmetros p e q
p_range <- 0:3
q_range <- 0:3

# Inicializando objetos para armazenar os modelos e resultados
modelos <- list()
resultados <- data.frame(p = integer(), d = integer(), q = integer(),
                        AIC = double(), BIC = double(), stringsAsFactors = FALSE)

# Loop para testar todas as combinações de p e q
for (p in p_range) {
  for (q in q_range) {
    order_spec <- c(p, 0, q)
    modelo_atual <- try(arima(IBC_BR_diff, order = order_spec), silent = TRUE)
    if (!inherits(modelo_atual, "try-error")) {
      aic_val <- AIC(modelo_atual)
      bic_val <- BIC(modelo_atual)
      resultados <- rbind(resultados, data.frame(p = p, d = 0, q = q,
                                                AIC = aic_val, BIC = bic_val))

      nome_modelo <- paste("ARIMA(", p, ",", 0, ",", q, ")", sep = "")
      modelos[[nome_modelo]] <- modelo_atual
      cat(sprintf("Modelo %s: AIC = %.2f, BIC = %.2f\n", nome_modelo, aic_val, bic_val))
    }
  }
}
```

```
## Modelo ARIMA(0,0,0): AIC = -1595.80, BIC = -1588.64
## Modelo ARIMA(0,0,1): AIC = -1605.96, BIC = -1595.22
## Modelo ARIMA(0,0,2): AIC = -1604.04, BIC = -1589.72
## Modelo ARIMA(0,0,3): AIC = -1606.42, BIC = -1588.52
## Modelo ARIMA(1,0,0): AIC = -1604.45, BIC = -1593.71
## Modelo ARIMA(1,0,1): AIC = -1604.00, BIC = -1589.68
## Modelo ARIMA(1,0,2): AIC = -1602.36, BIC = -1584.46
## Modelo ARIMA(1,0,3): AIC = -1604.48, BIC = -1583.00
## Modelo ARIMA(2,0,0): AIC = -1605.34, BIC = -1591.02
## Modelo ARIMA(2,0,1): AIC = -1605.38, BIC = -1587.48
## Modelo ARIMA(2,0,2): AIC = -1604.93, BIC = -1583.45
## Modelo ARIMA(2,0,3): AIC = -1602.91, BIC = -1577.86
## Modelo ARIMA(3,0,0): AIC = -1604.44, BIC = -1586.54
## Modelo ARIMA(3,0,1): AIC = -1603.03, BIC = -1581.56
## Modelo ARIMA(3,0,2): AIC = -1601.46, BIC = -1576.40
## Modelo ARIMA(3,0,3): AIC = -1602.17, BIC = -1573.53
```

```
# Visualizando a tabela de resultados
print(resultados)
```

```
##      p d q      AIC      BIC
## 1  0 0 0 -1595.799 -1588.640
## 2  0 0 1 -1605.963 -1595.223
## 3  0 0 2 -1604.041 -1589.722
## 4  0 0 3 -1606.420 -1588.521
## 5  1 0 0 -1604.446 -1593.707
```

```
## 6  1 0 1 -1604.001 -1589.682
## 7  1 0 2 -1602.355 -1584.457
## 8  1 0 3 -1604.480 -1583.002
## 9  2 0 0 -1605.337 -1591.018
## 10 2 0 1 -1605.380 -1587.482
## 11 2 0 2 -1604.929 -1583.451
## 12 2 0 3 -1602.913 -1577.855
## 13 3 0 0 -1604.436 -1586.537
## 14 3 0 1 -1603.034 -1581.555
## 15 3 0 2 -1601.458 -1576.400
## 16 3 0 3 -1602.172 -1573.534
```

Seleção e Estimação do Modelo ARIMA

Selecionamos o modelo que apresentou o menor AIC a partir da busca no grid e o comparamos com o resultado automático do `auto.arima()`.

```
# Selecionando o melhor modelo baseado no menor AIC
melhor_index <- which.min(resultados$AIC)
melhor_modelo_params <- resultados[melhor_index, ]
nome_melhor_modelo <- paste("ARIMA(", melhor_modelo_params$p, ",",
                             melhor_modelo_params$d, ",", melhor_modelo_params$q, ")", sep = "")
melhor_modelo <- modelos[[nome_melhor_modelo]]
cat("Melhor modelo selecionado:", nome_melhor_modelo,
    "com AIC =", melhor_modelo_params$AIC, "\n")
```

```
## Melhor modelo selecionado: ARIMA(0,0,3) com AIC = -1606.42
```

Comparando com o modelo sugerido pelo `auto.arima()`:

```
modelo_auto <- auto.arima(IBC_BR_diff)
cat("Modelo sugerido pelo auto.arima():\n")
```

```
## Modelo sugerido pelo auto.arima():
```


```
summary(modelo_auto)
```

```
## Series: IBC_BR_diff
## ARIMA(0,0,1) with non-zero mean
##
## Coefficients:
##          ma1      mean
##          0.2208  0.0017
## s.e.    0.0596  0.0009
##
## sigma^2 = 0.0001346:  log likelihood = 805.98
## AIC=-1605.96  AICc=-1605.87  BIC=-1595.22
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -1.261562e-05 0.01155691 0.007273832 401.0618 613.1381 0.7031288
##              ACF1
## Training set -0.004269051
```

Diagnóstico dos Resíduos

- Analisamos os resíduos do modelo ajustado para confirmar sua adequação.
- Os resíduos de um modelo bem estimado devem se comportar como um ruído branco, sem evidências de autocorrelação e com distribuição aproximadamente normal:

```
checkresiduals(melhor_modelo)
```




```
##  
##  Ljung-Box test  
##  
## data:  Residuals from ARIMA(0,0,3) with non-zero mean  
## Q* = 13.824, df = 21, p-value = 0.877  
##  
## Model df: 3.   Total lags used: 24
```

Previsão e Conclusões

- Agora, tendo o modelo que **melhor se ajusta aos dados**, podemos utilizá-lo para gerar previsões:

```
# Gerando previsões para os próximos 12 períodos  
previsoes <- forecast(melhor_modelo, h = 12)  
autoplot(previsoes) +  
  ggtitle("Previsão do IBC-BR com o Melhor Modelo ARIMA") +  
  xlab("Tempo") +  
  ylab("IBC-BR Previsto")
```

```
print(previsoes)
```

##	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
## Mar 2025	0.0024065592	-0.01227828	0.01709140	-0.02005196	0.02486508
## Apr 2025	0.0003300227	-0.01470337	0.01536341	-0.02266156	0.02332161
## May 2025	0.0015698462	-0.01348112	0.01662081	-0.02144862	0.02458832
## Jun 2025	0.0016438116	-0.01356715	0.01685477	-0.02161934	0.02490696
## Jul 2025	0.0016438116	-0.01356715	0.01685477	-0.02161934	0.02490696
## Aug 2025	0.0016438116	-0.01356715	0.01685477	-0.02161934	0.02490696
## Sep 2025	0.0016438116	-0.01356715	0.01685477	-0.02161934	0.02490696
## Oct 2025	0.0016438116	-0.01356715	0.01685477	-0.02161934	0.02490696
## Nov 2025	0.0016438116	-0.01356715	0.01685477	-0.02161934	0.02490696
## Dec 2025	0.0016438116	-0.01356715	0.01685477	-0.02161934	0.02490696
## Jan 2026	0.0016438116	-0.01356715	0.01685477	-0.02161934	0.02490696
## Feb 2026	0.0016438116	-0.01356715	0.01685477	-0.02161934	0.02490696

Resumo e Discussão

- **Interpretação dos Resultados do Grid Search:** Essa etapa facilita a compreensão dos impactos das diferentes combinações de p e q na qualidade do ajuste medido pelo AIC e BIC.
- **Comparação com Métodos Automáticos:** Comparar o modelo selecionado manualmente com o `auto.arima()` pode gerar debates enriquecedores sobre as vantagens e limitações de cada método.
- **Possibilidades e Extensões da Abordagem:**
 - Investigação do uso de variáveis exógenas (ARIMAX).
 - Validação cruzada da robustez dos modelos.

- Exploração de transformações logarítmicas e modelagem de volatilidade.