

Aula 8: Processos Não-Estacionários

Silvio Costa

2025-10-06

Processos Não-Estacionários

Motivação

- Até o momento, focamos em séries de retornos que tendem a ser estacionárias.
- Porém, em alguns estudos temos interesse na avaliação de outras séries temporais (taxa de juros, câmbio, inflação, crescimento econômico, ...).
- Quando a série temporal não é estacionária, não se pode estimá-la trivialmente.
- O procedimento básico é diferenciar a série, tantas vezes quantas sejam necessárias para estacionarizá-las.
- De modo geral, temos:

$$y_t = \text{tendência} + \text{componente estacionário} + \text{ruído}$$

- Exemplos de processos não-estacionários importantes que vamos explorar:

```
# Carregar pacotes necessários
library(ggplot2)
library(gridExtra)

# Definir parâmetros
set.seed(12345)
n <- 200
t <- 1:n

# Gerar séries temporais
random_walk <- 100 + cumsum(rnorm(n))
random_walk_drift <- 100 + cumsum(rnorm(n) + 0.5)
trend_stationary <- 100 + 0.05 * t + rnorm(n)
random_walk_noise <- 100 + cumsum(rnorm(n)) + rnorm(n)


# Criar gráficos
p1 <- ggplot(data.frame(t, random_walk), aes(x = t, y = random_walk)) +
  geom_line() + ggtitle("Passeio Aleatório")

p2 <- ggplot(data.frame(t, random_walk_drift), aes(x = t, y = random_walk_drift)) +
  geom_line() + ggtitle("Passeio Aleatório com Drift")

p3 <- ggplot(data.frame(t, trend_stationary), aes(x = t, y = trend_stationary)) +
  geom_line() + ggtitle("Tendência Estacionária")
```

```
p4 <- ggplot(data.frame(t, random_walk_noise), aes(x = t, y = random_walk_noise)) +  
  geom_line() + ggtitle("Passeio Aleatório com Ruído")
```

```
# Plotar gráficos em um layout 2x2  
grid.arrange(p1, p2, p3, p4, ncol = 2)
```



Séries Integradas

- Suponha o seguinte modelo:

$$y_t = y_{t-1} + \delta + \epsilon_t$$

- É equivalente a um AR(1) com o coeficiente $\phi = 1$. Já vimos que esse coeficiente implica que o processo não tem variância definida (falha da condição de estabilidade)
- Entretanto, ao diferenciar a série

$$\Delta y_t = \delta + \epsilon_t$$

é fácil ver que a série se torna estacionária.

- Define-se y_t como uma série temporal de tendência estocástica. Séries temporais cujo componente de tendência é estocástico são chamadas séries integradas.

Tendência Estocástica 1: Passeio Aleatório

- Séries integradas são denotadas por $I(d)$, e quando o termo de erro ϵ_t é estacionário são chamadas séries ARIMA(p, d, q).
- No caso de $I(1)$ e $\delta = 0$, o modelo fica:

$$y_t = y_{t-1} + \epsilon_t$$

- O modelo pode ser reescrito de forma recursiva como:

$$y_t = y_0 + \sum_{i=1}^t \epsilon_i$$

- A previsão condicional é dada simplesmente pela observação atual. O que isso significa?

$$E_t(y_{t+h}) = y_t + \sum_{h=1}^H E_t(\epsilon_{t+h}) = y_t$$

- Já as covariâncias e correlações dependem do tempo:

$$\text{Var}(y_t) = \text{Var}\left(\sum_{i=1}^t \epsilon_i\right) = t\sigma^2$$

$$\text{Cov}(y_t, y_{t-j}) = E\left(\sum_{i=1}^t \epsilon_i \sum_{s=1}^{t-j} \epsilon_s\right) = (t-j)\sigma^2$$

$$\rho_j = \frac{(t-j)\sigma^2}{\sqrt{t\sigma^2}\sqrt{(t-j)\sigma^2}} = \sqrt{\frac{1-j}{t}}$$

- Importante: vimos em aulas anteriores que quando o processo não é estacionário, como no caso do passeio aleatório, as autocorrelações são elevadas e demoram a cair.

Tendência Estocástica 2: Passeio Aleatório com Drift

- No caso de $I(1)$ e $\delta = 1$:

$$y_t = y_{t-1} + \delta + \epsilon_t$$

- O processo pode ser reescrito de forma recursiva como:

$$y_t = y_0 + \delta t + \sum_{i=1}^t \epsilon_i$$

- Veja que agora y_t depende tanto de um componente determinístico δt quanto de um estocástico.
- A previsão condicional é dada por:

$$E_t(y_{t+h}) = y_t + \delta h + \sum_{h=1}^H E_t(\epsilon_{t+h}) = y_t + \delta h$$

Tendência Estocástica 3: Passeio Aleatório com Ruído

- Partimos do Passeio Aleatório puro (sem drift, $\delta = 0$):

$$y_t = y_{t-1} + \epsilon_t$$

- Adicionamos η_t , um ruído branco:

$$y_t = y_0 + \sum_{i=1}^t \epsilon_i + \eta_t$$

- Podemos diferenciar o processo:

$$\Delta y_t = \epsilon_t + \Delta \eta_t$$

- Este modelo $I(1)$ possui uma correlação menor do que o Passeio Aleatório puro (compare):

$$\text{Var}(y_t) = \text{Var}\left(\sum_{i=1}^t \epsilon_i + \eta_t\right) = t\sigma^2 + \sigma_\eta^2$$

$$\text{Cov}(y_t, y_{t-j}) = E\left(\sum_{i=1}^t \epsilon_i + \eta_t \sum_{s=1}^{t-j} \epsilon_s + \eta_{t-j}\right) = (t-j)\sigma^2$$

$$\rho_j = \frac{(t-j)\sigma^2}{\sqrt{t\sigma^2 + \sigma_\eta^2}\sqrt{(t-j)\sigma^2 + \sigma_\eta^2}} < \sqrt{\frac{1-j}{t}}$$

Tendência Estocástica 4: Determinística + Estacionária

- Suponha o seguinte modelo:

$$y_t = y_0 + \delta t + \psi(L)\epsilon_t$$

- Repare que há uma parte da equação que depende do tempo, defina

$$f(t) = y_0 + \delta t$$

como a tendência determinística da série

- $\psi(L)$ é um polinômio no operador de defasagem que captura a estrutura do processo estocástico, indicando que os choques podem ter um efeito dinâmico ao longo do tempo.
- O produto $\psi(L)\epsilon_t$ indica uma estrutura autorregressiva e/ou de médias móveis.
- Ao diferenciar a série, a série diferenciada tem uma constante δ (tendência) e uma parte estocástica modificada por $(1-L)$.

$$\Delta y_t = (1-L)y_t = \delta + (1-L)\psi(L)\epsilon_t$$

- Importante: Nesse caso, a diferenciação de uma série com tendência determinística não é a melhor opção, pois o termo de erro da série diferenciada é um polinômio de defasagens.

Modelo Geral

- O modelo mais geral possível inclui tendência determinística e estocástica, além de erros que seguem um processo ARMA(p, q).
- Chamaremos este modelo de tendência geral mais componente irregular:

$$y_t = y_0 + \delta t + \psi(L)\eta_t + \sum_{i=1}^t \epsilon_i$$

, em que η_t é um ruído branco.

- O Passeio Aleatório e suas variações (com Drift ou Ruído) são casos particulares do modelo geral.
- Os processos que contêm tendência estocástica também são chamados de diferença estacionária, porque ao diferenciar a série se obtém um processo estacionário (resíduos são ruído branco).

- No caso particular do processo de tendência estacionária, a diferenciação também torna a série estacionária, mas os resíduos divergem de um ruído branco (são um polinômio de combinações de defasagens que impõem dependência temporal)
- Dessa forma, é de extrema importância avaliar o tipo de tendência da série e como iremos tratá-la.

Removendo a Tendência Determinística

- Vamos estimar uma regressão de y_t contra o vetor de tempo t e armazenar os resíduos. Esta série de resíduos será modelada separadamente.

- Etapas:

1. Estimamos a regressão:

$$y_t = \delta_0 + \delta_1 t + \delta_2 t^2 + \dots + \delta_n t^n + \epsilon_t$$

, em que $e_t = \psi(L)\epsilon_t$, obtendo assim os resíduos estimados $\hat{e}_t$

2. Estime um modelo ARMA(p, q) a partir dos resíduos estimados.
 3. Para determinar o número de parâmetros n , use os testes convencionais como t – *Student* e F .
 4. Em geral, estimamos o modelo com um n máximo e aplicamos os testes t e F até o momento em que os parâmetros rejeitem a hipótese nula.
- Importante: se a série temporal possui tendência determinística, é necessário utilizar essa metodologia.

Teste de Raiz Unitária

- A ordem de integração I de uma série temporal indica o número de raízes unitárias presentes na série
- Série $I(1) \rightarrow 1$ raiz unitária, Série $I(2) \rightarrow 2$ raízes unitárias, ...
- A ordem de integração está associada a um problema de estabilidade dos processos estocásticos, por exemplo no caso de um AR(1) em que $\phi = 1$.
- Os Testes de Raiz Unitária partem dessa intuição, vamos verificar $H_0 : \phi = 1$.
- Todavia, os testes vão ajudar a descobrir se a série possui tendência estacionária determinística ou tendência estocástica. A análise visual é um método impreciso para distinguir estas duas possibilidades.
- Partimos do modelo $y_t = \phi y_{t-1} + \epsilon_t$ em que queremos testar $H_0 : \phi = 1$
- Entretanto, podemos modificar o teste da seguinte forma:

$$y_t - y_{t-1} = \phi y_{t-1} - y_{t-1} + \epsilon_t$$

$$\Delta y_t = (\phi - 1)y_{t-1} + \epsilon_t$$

$$\Delta y_t = \alpha y_{t-1} + \epsilon_t$$

- Agora testar $H_0 : \alpha = 0$ é equivalente a testar para $\phi = 1$. Porém o teste para α é melhor porque podemos ter uma resposta ainda mais precisa se, após a diferenciação da série, ainda há uma segunda raiz unitária.
- O problema é que, sob a hipótese nula, esse teste não possui uma distribuição convencional como a de t -student. Simulações de Monte Carlo mostram que a distribuição estatística não é simétrica.
- Dessa forma, usar a estatística t para inferir sobre α aumentará a chance de erros do tipo I (rejeitar H_0 e assumir estacionaridade quando, na verdade, há raiz unitária).

Dickey e Fuller

- Dickey e Fuller (1979) resolvem essa questão ao recalculer a estatística t para estes casos.
- Primeiro, eles consideraram diferentes estatísticas dependendo se o processo possuía drift e/ou tendência determinística. Ou seja:

$$\Delta y_t = \alpha y_{t-1} + \epsilon_t \rightarrow \tau$$

$$\Delta y_t = \mu + \alpha y_{t-1} + \epsilon_t \rightarrow \tau_\mu$$

$$\Delta y_t = \mu + \delta t + \alpha y_{t-1} + \epsilon_t \rightarrow \tau_\tau$$

- O principal mérito de Dickey e Fuller (1979) foi estimar repetidas simulações de Monte Carlo de amostras que variavam de $T = 25$ até ∞ observações para cada uma dessas equações. A partir dessas simulações foram mapeados os τ críticos que são usados nos testes de hipóteses.
- Importante: Na especificação mais completa, a significância do parâmetro δ nos diz se há ou não tendência determinística.
- Usando os τ críticos mapeados por Dickey e Fuller (1979), o teste de hipóteses segue os passos habituais. Com $H_0 : \alpha = 0$, a estatística é dada por:

$$\hat{\tau} = \frac{\hat{\alpha}}{s(\hat{\alpha})}$$

onde o valor do coeficiente $\hat{\alpha}$ estimado é:

$$\hat{\alpha} = \frac{\sum_{t=1}^T y_{t-1} y_t}{\sum_{t=1}^T y_{t-1}^2} - 1$$

S^2 é a variância amostral dada por:

$$S^2 = \frac{1}{T-1} \sum_{t=1}^T (\Delta y_t - \hat{\alpha} y_{t-1})^2$$

e o desvio-padrão do coeficiente $s(\hat{\alpha})$ é dado por:

$$s(\hat{\alpha}) = \frac{S}{\sqrt{\sum_{t=1}^T y_{t-1}^2}}$$

- Rejeitamos a hipótese nula se $\hat{\tau} < \tau_{Dickey-Fuller}$, usando enfim os valores críticos das simulações de Monte Carlo.
- Rejeitar a hipótese nula $\rightarrow$ Não há Raiz Unitária e vale a hipótese alternativa: o processo é estacionário.

Dickey-Fuller Aumentado

- O teste de Dickey e Fuller (1979) parte da premissa de que o erro é ruído branco.
- Na prática, frequentemente o erro é um processo estacionário qualquer.
- Suponha y_t um processo AR:

$$y_t = \mu + \phi_1 y_{t-1} + \dots + \phi_{p-1} y_{t-p+1} + \phi_p y_{t-p} + \varepsilon_t$$

- Usando um pouco de álgebra e diferenciando a expressão, obtemos:

$$\Delta y_t = \mu + \alpha y_{t-1} + \sum_{i=1}^{p-1} \lambda_i \Delta y_{t-i} + \varepsilon_t$$
$$\alpha = - \left(1 - \sum_{i=1}^p \phi_i \right) \quad \lambda_i = - \sum_{j=i}^{p-1} \phi_{j+1}$$

- Essa correção permite usar os t críticos do teste padrão de Dickey-Fuller.
- Nota: mesmo que y_t siga um processo mais complexo com a inclusão de termos de médias móveis, Said e Dickey (1984) mostram que modelos ARIMA(m,1,n) são bem aproximados por um ARIMA(p,1,0).
- Neste contexto, p é o número de defasagens do AR necessárias para que os resíduos sejam ruído branco.

Teste de Dickey-Fuller no R

```
# Carregar pacotes necessários
library(rbc)
library(tseries)

## Registered S3 method overwritten by 'quantmod':
##   method      from
##   as.zoo.data.frame zoo

# Exemplo de série temporal de PIB (substitua com seus dados reais)
data.pib = get_series(22109, start_date = '1995-01-01')
PIB = ts( data.pib$`22109`, start = c( 1995, 1 ), frequency = 4 )      # PIB

# Realizar o teste de Dickey-Fuller
adf_test <- adf.test(PIB)

# Exibir os resultados do teste
print(adf_test)

##
##   Augmented Dickey-Fuller Test
##
## data:  PIB
## Dickey-Fuller = -1.451, Lag order = 4, p-value = 0.8046
## alternative hypothesis: stationary

# Realizar o teste de Dickey-Fuller no PIB em LOG???
adf_test <- adf.test(log(PIB))
```

```

# Exibir os resultados do teste
print(adf_test)

##
## Augmented Dickey-Fuller Test
##
## data: log(PIB)
## Dickey-Fuller = -1.1896, Lag order = 4, p-value = 0.9049
## alternative hypothesis: stationary
# Realizar o teste de Dickey-Fuller na taxa de crescimento do PIB:
adf_test <- adf.test(log(PIB)/lag(PIB))

## Warning in adf.test(log(PIB)/lag(PIB)): p-value smaller than printed p-value
# Exibir os resultados do teste
print(adf_test)

##
## Augmented Dickey-Fuller Test
##
## data: log(PIB/lag(PIB))
## Dickey-Fuller = -4.457, Lag order = 4, p-value = 0.01
## alternative hypothesis: stationary

```

Philips-Perron

- Philips e Perron (1988) apresentam um teste consistente mesmo nos casos em que haja variáveis defasadas no tempo e correlação serial nos erros.
- A intuição é verificar a presença de raiz unitária independente das ordens p e q de um ARIMA(p,1,q). Isso elimina a necessidade de se especificar um modelo AR para expurgar a correlação serial dos resíduos.
- Processo de estimação bastante semelhante ao de Dickey-Fuller.
- Considere o sistema de equações:

$$\Delta y_t = \alpha y_{t-1} + u_t \rightarrow z_t$$

$$\Delta y_t = \mu + \alpha y_{t-1} + u_t \rightarrow z_{t,\mu}$$

$$\Delta y_t = \mu + \delta t + \alpha y_{t-1} + u_t \rightarrow z_{t,\tau}$$

- Etapas:

1. Estimar as médias amostrais:

$$\bar{y} = \frac{\sum_{t=1}^T y_t}{T} \quad \bar{y}_{-1} = \frac{\sum_{t=1}^T y_{t-1}}{T}$$

2. Estimar o parâmetro do componente AR:

$$\hat{\alpha} = \frac{\sum_{t=1}^T (y_{t-1} - \bar{y}_{-1})(y_t - \bar{y})}{\sum_{t=1}^T (y_{t-1} - \bar{y}_{-1})^2} - 1$$

3. Estimar a constante ou “drift”:

$$\hat{\mu} = \bar{y} - (\hat{\alpha} + 1)\bar{y}_{-1}$$

4. Estimar a variância:

$$\hat{\sigma}^2 = \frac{\sum_{t=1}^T \hat{\mu}_t^2}{T} = \frac{\sum_{t=1}^T (\Delta y_t - \hat{\mu} - \hat{\alpha} y_{t-1})^2}{T}$$

5. Estimar o desvio-padrão do parâmetro do componente AR:

$$s(\hat{\alpha}) = \frac{\hat{\sigma}}{\sqrt{\sum_{t=1}^T y_{t-1}^2}}$$

6. Calcular a estatística de Dickey e Fuller:

$$\hat{\tau}_\mu = \frac{\hat{\alpha}}{s(\hat{\alpha})}$$

7. Estimar a variância de longo prazo HAC (Heteroscedasticity and Autocorrelation Consistent). É uma medida estatística utilizada para ajustar a variância estimada de uma série temporal, levando em consideração a presença de heteroscedasticidade e autocorrelação nos erros:

$$\hat{v}^2 = \hat{\sigma}^2 + \frac{2}{T} \sum_{j=1}^M \omega\left(\frac{j}{M+1}\right) \sum_{t=j+1}^T \hat{\mu}_t \hat{\mu}_{t-j}$$

8. Por fim, calcular a estatística de Philips-Perron:

$$\hat{z}_{t,\mu} = \hat{\tau}_\mu \left(\frac{\hat{\sigma}}{\hat{v}} \right) - \frac{1}{2} \left(\frac{\hat{v}^2 - \hat{\sigma}^2}{\hat{v} \sqrt{T^{-2} \sum_{t=1}^T y_{t-1}^2}} \right)$$

- Nota: o teste de Philips-Perron é problemático quando α é muito próximo de zero. Nesse caso, o poder do teste é baixo, ou seja, tem dificuldade de rejeitar a nula quando ela é falsa.

```
# Teste Phillips-Perron
pp_test <- pp.test(log(PIB))
```

```
# Veja os resultados
print(pp_test)
```

```
##
## Phillips-Perron Unit Root Test
##
## data: log(PIB)
## Dickey-Fuller Z(alpha) = -3.7846, Truncation lag parameter = 4, p-value
## = 0.8975
## alternative hypothesis: stationary
```

```
# Teste Phillips-Perron
pp_test <- pp.test(log(PIB/lag(PIB)))
```

```
## Warning in pp.test(log(PIB/lag(PIB))): p-value smaller than printed p-value
```

```
# Veja os resultados
print(pp_test)
```

```
##
## Phillips-Perron Unit Root Test
##
## data: log(PIB/lag(PIB))
## Dickey-Fuller Z(alpha) = -100.62, Truncation lag parameter = 4, p-value
```

```
## = 0.01
## alternative hypothesis: stationary
```

KPSS

- Teste criado por Kwiatkowski, Philips, Schmidt e Shin(1992) para lidar com o baixo poder dos testes tradicionais Dickey-Fuller e Philips-Perron.

$$H_0 : y_t \sim I(0) H_1 : y_t \sim I(1)$$

- Considere o sistema de equações:

$$y_t = x_t + u_t$$

$$x_t = x_{t-1} + \delta_t + v_t$$

$$\delta_t = \delta_{t-1} + \zeta_t$$

em que ζ_t é ruído branco.

- Objetivo do teste: verificar a variância do passeio aleatório x_t .

$$H_0 : \sigma_v^2 = 0 H_1 : \sigma_v^2 > 0$$

- Não rejeitar $H_0 \rightarrow$ Processo Estacionário.
- Isso traz uma evidência adicional de que a série não possui raiz unitária.

```
# Teste KPSS
```

```
kpss_test <- kpss.test(log(PIB))
```

```
## Warning in kpss.test(log(PIB)): p-value smaller than printed p-value
```

```
# Veja os resultados
```

```
print(kpss_test)
```

```
##
```

```
## KPSS Test for Level Stationarity
```

```
##
```

```
## data: log(PIB)
```

```
## KPSS Level = 2.291, Truncation lag parameter = 4, p-value = 0.01
```

```
# Teste KPSS
```

```
kpss_test <- kpss.test(log(PIB/lag(PIB)))
```

```
## Warning in kpss.test(log(PIB/lag(PIB))): p-value greater than printed p-value
```

```
# Veja os resultados
```

```
print(kpss_test)
```

```
##
```

```
## KPSS Test for Level Stationarity
```

```
##
```

```
## data: log(PIB/lag(PIB))
```

```
## KPSS Level = 0.21902, Truncation lag parameter = 4, p-value = 0.1
```

