

Aula 9: Modelos GARCH

Silvio Costa

2025-10-06

Modelos de Heterocedasticidade Condicional

- Vimos que uma das premissas fundamentais dos modelos ARIMA é que o termo de erro ϵ_t é um ruído branco.
- Usando as técnicas de diagnóstico dos resíduos, testamos empiricamente algumas dessas propriedades dos modelos como a distribuição normal (Teste de Jarque-Bera) e a variância constante (Teste ARCH-LM).
- Na prática: vimos que nem sempre conseguimos obter um modelo para o qual os resíduos se comportem de fato como um ruído branco!!
- Mesmo para um modelo estacionarizado por diferenças (por exemplo, retorno diário de um ativo), mesmo passando no teste de Ljung-Box, os resíduos obtidos não passaram pelos testes de Jarque-Bera e ARCH-LM!!!
- A heteroscedasticidade é um problema que viola as premissas dos modelos ARIMA!! A presença de heteroscedasticidade atrapalha a estimação da variância dos coeficientes. Mesmo que os parâmetros estimados sejam consistentes, a eficiência do estimador é comprometida. Isso gera problemas de inferência!!
- Nesse caso, para alguns problemas econômico-financeiros, precisamos tratar da estrutura dos resíduos para realizar inferências de maneira robusta.

Motivação:

- Modelos se preocupam mais com a média e pouco com a variância. A importância do risco e incerteza sobre uma projeção é tão importante quanto o número per se.
- Fama & French, 2004: discussão sobre as limitações do modelo CAPM para precificação de ativos. Não modelam adequadamente do risco/incerteza!
 - CAPM tem fraco desempenho empírico: beta vs retorno não se confirma nos dados. Variação dos retornos não é explicada apenas pelo beta
- A heterocedasticidade condicional é uma característica bastante frequente em séries financeiras. As séries financeiras não tem distribuição normal padrão, pois tem probabilidade elevada de eventos extremos e excesso de curtose.
- Os modelos ARCH e GARCH tem sido desenvolvidos desde a década de 1980 como forma de estimar a variância condicional, sem considerá-la necessariamente constante ao longo do tempo.

Exemplo: modelagem ARIMA para o IBOVESPA

```
# Carregamento dos pacotes necessários
library(quantmod)      # Para importar dados financeiros
```

```
## Loading required package: xts
```

```
## Loading required package: zoo
```

```

##
## Attaching package: 'zoo'

## The following objects are masked from 'package:base':
##
##   as.Date, as.Date.numeric

## Loading required package: TTR

## Registered S3 method overwritten by 'quantmod':
##   method      from
##   as.zoo.data.frame zoo

library(forecast)      # Para modelagem ARIMA e diagnóstico
library(tseries)       # Para teste de estacionariedade (ADF)
library(FinTS)         # Para teste ARCH de heteroscedasticidade

##
## Attaching package: 'FinTS'

## The following object is masked from 'package:forecast':
##
##   Acf

# Importação dos dados do IBOVESPA a partir do Yahoo Finance
getSymbols("^BVSP", src = "yahoo", from = "2018-01-01", auto.assign = TRUE)

## Warning: ^BVSP contains missing values. Some functions will not work if objects
## contain missing values in the middle of the series. Consider using na.omit(),
## na.approx(), na.fill(), etc to remove or replace them.

## [1] "BVSP"

ibov <- na.omit(Cl(BVSP)) # Seleciona apenas os preços de fechamento e remove NAs

# Transformação logarítmica para estabilizar a variância
log_ibov <- log(ibov)


# Diferenciação para tornar a série estacionária
diff_ibov <- diff(log(ibov))[-1]

# Visualização da série temporal original
plot(ibov, main = "IBOVESPA - Fechamento Diário", col = "blue")

```

IBOVESPA – Fechamento Diário

2018-01-02 / 2025-10-03




Visualização dos retornos logarítmicos

```
plot(diff_ibov, main = "Retornos Logarítmicos Diários", col = "darkgreen")
```


Retornos Logarítmicos Diários

2018-01-03 / 2025-10-03




```
par(mfrow=c(1,2))  
acf(diff_ibov)  
pacf(diff_ibov)
```

Series diff_ibov



Series diff_ibov



```
# Ajuste automático do modelo ARIMA
```

```
fit <- auto.arima(log_ibov)
```

```
summary(fit)
```

```
## Series: log_ibov
```

```
## ARIMA(0,1,2)
```

```
##
```

```
## Coefficients:
```

```
##          ma1      ma2
```

```
##        -0.1321  0.0660
```

```
## s.e.    0.0228  0.0227
```

```
##
```

```
## sigma^2 = 0.0002201: log likelihood = 5381.01
```

```
## AIC=-10756.01  AICc=-10756  BIC=-10739.32
```

```
##
```

```
## Training set error measures:
```

```
##              ME          RMSE          MAE          MPE          MAPE          MASE
```

```
## Training set 0.0003474466 0.0148244 0.01014531 0.002915601 0.0878966 1.001899
```

```
##              ACF1
```

```
## Training set 0.001115666
```

```
resids <- residuals(fit)
```

```
# Estimar a densidade kernel
```

```
densidade <- density(resids, kernel = "gaussian")
```

```
# Plotar a densidade kernel
```


```
plot(densidade, main = "Estimativa de Densidade Kernel", col = "black", lwd=2)
```

```
hist(resids, freq = FALSE, add = TRUE, breaks = 100, col = "lightblue")
```

```
sigma_emp = sd(resids)
lines(density(rnorm(10000,0, sigma_emp)), col = "red", lwd=2)

lines(densidade, col = "black", lwd=2)
```


Estimativa de Densidade Kernel



```
# Diagnóstico dos resíduos

# Verificação gráfica dos resíduos
checkresiduals(fit)
```

Residuals from ARIMA(0,1,2)



```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(0,1,2)
## Q* = 53.429, df = 8, p-value = 8.907e-09
##
## Model df: 2.    Total lags used: 10
# Teste de Ljung-Box para autocorrelação dos resíduos
Box.test(resids, lag = 20, type = "Ljung-Box")

##
##  Box-Ljung test
##
## data:  resids
## X-squared = 79.682, df = 20, p-value = 4.446e-09
# Teste ARCH para heteroscedasticidade nos resíduos
ArchTest(resids, lags = 12)

##
##  ARCH LM-test; Null hypothesis: no ARCH effects
##
## data:  resids
## Chi-squared = 713.53, df = 12, p-value < 2.2e-16
```

Modelos da família GARCH

ARCH(q): Autoregressive Conditional Heteroskedasticity

- O modelo mais simples para representar a variância dos resíduos foi apresentado por Engle (1982). Seja ϵ_t um processo estocástico condicional à informação em $t-1$ (por exemplo, os resíduos de um modelo da família ARIMA):

$$\epsilon_t = \sigma_t u_t \quad u_t \sim i.i.d(0, 1)$$
$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2$$

- Da mesma forma que nos modelos ARIMA, o modelo ARCH propõe uma estrutura autorregressiva sobre os resíduos passados. Precisamos verificar a estacionaridade deste modelo!
- A variância incondicional do processo ϵ_t é dada por:

$$var(\epsilon_t) = E(\epsilon_t^2) = E(\sigma_t^2 u_t^2) = \sigma_\epsilon^2 = \frac{\omega}{1 - \sum_{i=1}^q \alpha_i}$$

- Um ARCH(q) será estacionário e a variância estimada será bem definida se:
 - $\omega > 0$
 - $\alpha_i \geq 0$ para todo i
 - $\sum_{i=1}^q \alpha_i < 1$ (Condição de Estabilidade)

GARCH(p,q)

- O modelo GARCH é uma generalização do modelo ARCH, acrescentando uma parte autorregressiva para a dinâmica da variância:

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$$

- O modelo GARCH é mais parcimonioso do que o modelo ARCH. Por que?
- A variância do modelo GARCH é dada por:

$$E(\sigma_t^2) = \frac{\omega}{1 - \sum_{i=1}^q \alpha_i - \sum_{j=1}^p \beta_j}$$

- A condição suficiente para a estacionaridade é que as raízes do polinomial da variância estejam fora do círculo unitário, e:
 - $\omega > 0$
 - $\alpha_i, \beta_j \geq 0$ para todo i e j
 - $\sum_{i=1}^q \alpha_i + \sum_{j=1}^p \beta_j < 1$ (Condição de Estabilidade)
- Importante: a variância σ_t^2 é um processo determinístico, pois depende apenas de fatores passados e conhecidos. Logo, os modelos GARCH não são estocásticos (não tem resíduo).

Identificação dos modelos GARCH

- Há muitos casos em que os resíduos de modelos univariados não são homocedásticos.
- Neste caso, podemos usar modelos ARCH e GARCH são especificar a heterocedasticidade condicional dos modelos.

- A intuição é muito parecida com a dos modelos ARMA, com a diferença que os análogos dos termos AR(p) e MA(q) são construídos com base nos resíduos estimados para a variância σ_t^2 .
- Assim, os testes de identificação dos modelos ARCH(q) e GARCH(p,q) são construídos de forma muito semelhante ao que vimos para os modelos ARMA(p,q).

FAC e FACP

- As funções de autocorrelação (FAC) e autocorrelação parcial (FACP) seguem a mesma lógica utilizada para avaliar o ordem dos componentes AR(p) e MA(q).
- Parte-se da definição de variância como o quadrado dos erros estimados:

$$\bar{\sigma}^2 = \frac{1}{T} \sum_{t=1}^T \hat{\epsilon}_t^2$$

- FAC: com o quadrados dos resíduos, se calcula a correlação para cada período

$$\hat{\rho}_j = \frac{\sum_{t=j+1}^T (\hat{\epsilon}_t^2 - \bar{\sigma}^2)(\hat{\epsilon}_{t-j}^2 - \bar{\sigma}^2)}{\sum_{t=1}^T (\hat{\epsilon}_t^2 - \bar{\sigma}^2)}$$

- Haverá a possibilidade de um modelo da família GARCH se valores de $\hat{\rho}_j$ forem estatisticamente diferentes de zero.
- FACP: de maneira similar ao ARIMA, é obtida representando-se em um gráfico os coeficientes $\phi_{s,s}$ contra a defasagem s a partir da equação:

$$\hat{\epsilon}_t^2 = \phi_s + \phi_{s,1}\hat{\epsilon}_{t-1}^2 + \phi_{s,2}\hat{\epsilon}_{t-2}^2 + \dots + \phi_{s,s}\hat{\epsilon}_{t-s}^2 + u_t$$

- Importante: diferenças em relação à identificação nos modelos ARMA:
 - A FAC aqui nos dá a ordem máxima da autoregressão (GARCH) representada por $\hat{\epsilon}_{t-i}^2$
 - A FACP mostra a ordem máxima p de médias móveis, termo σ_{t-j}^2 .
- As dificuldades de estimação são as mesmas dos modelos ARMA(p,q)

Teste de Ljung-Box

- A estatística Q de Ljung-Box pode ser usada para testar a presença de heterocedasticidade condicional.
- Neste caso a hipótese nula é dada por

$$H_0 : \sum_{j=1}^n \hat{\rho}_j = 0$$

$$H_A : \hat{\rho}_j \neq 0$$

- Em que

$$Q = T(T+2) \sum_{j=1}^n \frac{\hat{\rho}_j^2}{T-j} \sim \chi_n^2$$

Teste LM

- Define-se o teste com base em Engle (1982) e Lee (1991)

$$H_0 : \alpha_1 = \alpha_2 = \dots = \alpha_q = 0$$

$$H_A : \alpha_i \neq 0$$

Em que:

$$\hat{\epsilon}_t^2 = \alpha_0 + \alpha_1 \hat{\epsilon}_{t-1}^2 + \alpha_2 \hat{\epsilon}_{t-2}^2 + \dots + \alpha_q \hat{\epsilon}_{t-s}^2 + u_t$$

- A estatística de teste é dada por

$$TR^2 \sim \chi_n^2$$

- Rejeitar a hipótese nula: indica que a covariância condicional não é constante.
- Para os modelos GARCH, ainda são válidas as análises dos Critérios de Informação de Akaike, Schwarz e Hannan-Quinn.
- Pela sua facilidade de aplicação e interpretação, este método é bastante utilizado para definir a melhor especificação dos modelos ARCH e GARCH.
- Uma peculiaridade nesta literatura são os testes de simetria do GARCH, que podem definir tipos específicos de modelo que podem ser empregados (Hegerud, 1997).


Exemplo: testando os resíduos do modelo IBOV:ARIMA(0,1,2)

```
sqr_resid <- resid^2

par(mfrow=c(1,2))

vacf = acf(sqr_resid, lag.max = 30, main="ACF")

vpacf = pacf(sqr_resid, lag.max =30, main="PACF")
```



```

# Teste de Ljung-Box para autocorrelação dos resíduos
Box.test(sqr_resid, lag = 30, type = "Ljung-Box")

##
## Box-Ljung test
##
## data:  sqr_resid
## X-squared = 2202.4, df = 30, p-value < 2.2e-16

library(lmtest)

# Ajuste um modelo linear com os resíduos defasados
mod_sqrresid_lm <- lm(sqr_resid ~ ., data = sqr_resid)
# summary(mod_resid_lm)

# Realizando o teste de Breusch-Godfrey para autocorrelação de ordem até 30
bg_test <- bgtest(mod_sqrresid_lm, order = 30, type = "Chisq")
# summary(bg_test)

# Exibindo os resultados
print(bg_test)

##
## Breusch-Godfrey test for serial correlation of order up to 30
##
## data:  mod_sqrresid_lm
## LM test = 72.621, df = 30, p-value = 2.145e-05

```

Estimação de Modelos

- Geralmente, usa-se o método de máxima verossimilhança.
- O uso do método da máxima verossimilhança depende de hipóteses sobre a verdadeira distribuição dos dados.
- Em geral costuma-se adotar a hipótese de Distribuição Normal. Entretanto, dados financeiros em geral são mais “pontagudos” que uma Normal Padrão (leptocurtose).
- Existem outras abordagens de estimação (GED, estimação de quase-máxima verossimilhança), vamos focar nas hipóteses de uma Distribuição Normal ou t-Student.
- Para dados distribuídos normalmente, temos a função de verossimilhança

$$L = L(\Theta; y_t) = \prod_{t=\kappa+1}^T \frac{1}{(2\pi\sigma_t^2)^{1/2}} \exp\left(-\frac{\epsilon_t^2}{2\sigma_t^2}\right)$$

em que Θ é o vetor de parâmetros a serem estimados da equação da média e da variância.

- Neste caso, a estimação utiliza os parâmetros iniciais da variância para a otimização

$$\sigma_1^2 = \sigma_2^2 = \dots = \sigma_\kappa^2 = \frac{1}{T} \sum_{t=1}^T \hat{\epsilon}_t^2$$

- Supondo a distribuição t-Student, temos a função de verossimilhança:

$$L = L(\Theta; y_t) = \prod_{t=\kappa}^T \left[\frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\Gamma\left(\frac{\nu}{2}\right) \sqrt{(\nu-2)\pi\sigma_t^2}} \exp\left(-1 - \frac{\epsilon_t^2}{(\nu-2)\sigma_t^2}\right) \right]$$

em que $\Gamma(\cdot)$ é a função gama e adota-se $\nu > 2$

- Quando $\nu \rightarrow \infty$, a distribuição converge para uma Normal.
- Neste caso, a obtenção dos parâmetros iniciais se dá por MQO, por um ajustamento de um modelo ARIMA, ou pelos parâmetros obtidos num teste LM.
- Atendidas as condições de regularidade, a máxima verossimilhança garante a consistência e normalidade assintótica dos estimadores.
- Entretanto, garantir estas condições nos modelos GARCH se mostra extremamente difícil na prática (Bollerslev, Engle e Nelson, 1994). Em geral se prova as condições de regularidade para cada modelos escolhido.
- No caso de um GARCH(1,1), Lumsdaine (1996) mostram quem para assegurar ergodicidade e estacionaridade é necessário que

$$E \ln |\alpha_1 u_t^2 + \beta_1| < 0$$

Para o qual pela desigualdade de Jensen, temos:

$$E \ln |\alpha_1 u_t^2 + \beta_1| < \ln E |\alpha_1 u_t^2 + \beta_1| = \ln(\alpha_1 u_t^2 + \beta_1)$$

```
# Instale os pacotes necessários, se ainda não tiver
#library(!require("rugarch")) install.packages("rugarch", dependencies = TRUE)
```

```
library(rugarch)
```

```
## Loading required package: parallel
```

```
##
```

```
## Attaching package: 'rugarch'
```

```
## The following object is masked from 'package:stats':
```

```
##
```

```
##      sigma
```

```
# Função para testar diferentes modelos GARCH
```

```
testar_modelos_garch <- function(residuos, max_p = 2, max_q = 2) {
```

```
  resultados <- data.frame(
```

```
    Modelo = character(),
```

```
    Ordem = character(),
```

```
    AIC = numeric(),
```

```
    BIC = numeric(),
```

```
    LogLik = numeric(),
```

```
    stringsAsFactors = FALSE
```

```
)
```

```
modelos <- c("sGARCH") # , "eGARCH", "gjrGARCH"
```

```
for (modelo in modelos) {
```

```
  for (p in 1:max_p) {
```

```
    for (q in 1:max_q) {
```

```
      spec <- ugarchspec(
```

```
        variance.model = list(model = modelo, garchOrder = c(p, q)),
```

```

    mean.model = list(armaOrder = c(0, 0), include.mean = FALSE),
    distribution.model = "norm"
  )

  fit <- tryCatch(
    ugarchfit(spec, residuos, solver = "hybrid"),
    error = function(e) NULL
  )

  if (!is.null(fit)) {
    resultados <- rbind(resultados, data.frame(
      Modelo = modelo,
      Ordem = paste0("(", p, ", ", q, ")"),
      AIC = infocriterias(fit)[1],
      BIC = infocriterias(fit)[2],
      LogLik = likelihood(fit)
    ))
  }
}
}
}

resultados[order(resultados$AIC), ]
}

# Exemplo de uso:
resultados <- testar_modelos_garch(resids, max_p = 4 , max_q = 4 )
print(resultados)

```

##	Modelo	Ordem	AIC	BIC	LogLik
## 1	sGARCH	(1,1)	-5.943043	-5.934385	5732.094
## 2	sGARCH	(1,2)	-5.942518	-5.930974	5732.587
## 6	sGARCH	(2,2)	-5.941999	-5.927569	5733.087
## 5	sGARCH	(2,1)	-5.941963	-5.930419	5732.053
## 10	sGARCH	(3,2)	-5.941449	-5.924133	5733.557
## 3	sGARCH	(1,3)	-5.941391	-5.926961	5732.501
## 9	sGARCH	(3,1)	-5.941032	-5.926601	5732.154
## 7	sGARCH	(2,3)	-5.940880	-5.923564	5733.008
## 11	sGARCH	(3,3)	-5.940859	-5.920657	5733.988
## 14	sGARCH	(4,2)	-5.940374	-5.920172	5733.521
## 4	sGARCH	(1,4)	-5.940305	-5.922988	5732.454
## 13	sGARCH	(4,1)	-5.939964	-5.922647	5732.125
## 8	sGARCH	(2,4)	-5.939797	-5.919594	5732.964
## 15	sGARCH	(4,3)	-5.939781	-5.916693	5733.949
## 12	sGARCH	(3,4)	-5.939781	-5.916693	5733.949
## 16	sGARCH	(4,4)	-5.938744	-5.912769	5733.949

Previsão

- Nos modelos econométricos convencionais, a incerteza do erro de previsão é crescente com o horizonte de tempo (e não depende do ponto de origem).
- Nos modelos de heterocedasticidade convencional, a acurácia da previsão depende do conjunto de informações disponíveis no momento da previsão. Assim, os intervalos de confiança exige a avaliação

das variâncias condicionais dos erros futuros.

- A dificuldade reside no fato dos erros não serem normalmente distribuídos, o que torna mais desafiador o trabalho de previsão.
- A previsão é análoga aos modelos ARIMA: prevê-se um passo à frente, com o resultado obtido, faz-se o passo seguinte e assim sucessivamente.

Exercício: Prever com GARCH

```
library(forecast)
library(rugarch)

# Ajustar ARIMA
fit_arima <- auto.arima(log_ibov)
summary(fit_arima)

## Series: log_ibov
## ARIMA(0,1,2)
##
## Coefficients:
##          ma1      ma2
##      -0.1321  0.0660
## s.e.   0.0228  0.0227
##
## sigma^2 = 0.0002201:  log likelihood = 5381.01
## AIC=-10756.01  AICc=-10756  BIC=-10739.32
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.0003474466 0.0148244 0.01014531 0.002915601 0.0878966 1.001899
##              ACF1
## Training set 0.001115666
```

GARCH sobre os resíduos:

```
# Ajustar ARIMA-GARCH
spec <- ugarchspec(
  variance.model = list(model = "sGARCH", garchOrder = c(1,1)),
  mean.model = list(armaOrder = c(0,0), include.mean = FALSE),
  distribution.model = "norm"
)

fit_garch <- ugarchfit(spec, residuals(fit_arima))

show(fit_garch)

##
## *-----*
## *          GARCH Model Fit          *
## *-----*
##
## Conditional Variance Dynamics
## -----
## GARCH Model   : sGARCH(1,1)
```

```

## Mean Model      : ARFIMA(0,0,0)
## Distribution    : norm
##
## Optimal Parameters
## -----
##           Estimate Std. Error  t value Pr(>|t|)
## omega      0.000003   0.000002   1.7463  0.08076
## alpha1     0.077880   0.011097   7.0180  0.00000
## beta1      0.903310   0.013708  65.8959  0.00000
##
## Robust Standard Errors:
##           Estimate Std. Error  t value Pr(>|t|)
## omega      0.000003   0.000006   0.5477  0.583902
## alpha1     0.077880   0.028278   2.7540  0.005886
## beta1      0.903310   0.038723  23.3273  0.000000
##
## LogLikelihood : 5732.094
##
## Information Criteria
## -----
##
## Akaike          -5.9430
## Bayes           -5.9344
## Shibata         -5.9430
## Hannan-Quinn   -5.9399
##
## Weighted Ljung-Box Test on Standardized Residuals
## -----
##                               statistic  p-value
## Lag[1]                      12.12 4.988e-04
## Lag[2*(p+q)+(p+q)-1] [2]    17.94 1.551e-05
## Lag[4*(p+q)+(p+q)-1] [5]    21.87 5.898e-06
## d.o.f=0
## H0 : No serial correlation
##
## Weighted Ljung-Box Test on Standardized Squared Residuals
## -----
##                               statistic  p-value
## Lag[1]                      0.01957  0.8887
## Lag[2*(p+q)+(p+q)-1] [5]    2.81858  0.4412
## Lag[4*(p+q)+(p+q)-1] [9]    7.80230  0.1408
## d.o.f=2
##
## Weighted ARCH LM Tests
## -----
##           Statistic Shape Scale P-Value
## ARCH Lag[3]      4.029 0.500 2.000 0.04472
## ARCH Lag[5]      4.447 1.440 1.667 0.13769
## ARCH Lag[7]      4.917 2.315 1.543 0.23310
##
## Nyblom stability test
## -----
## Joint Statistic:  9.6823
## Individual Statistics:

```

```

## omega 0.3944
## alpha1 0.5357
## beta1 0.4335
##
## Asymptotic Critical Values (10% 5% 1%)
## Joint Statistic:      0.846 1.01 1.35
## Individual Statistic: 0.35 0.47 0.75
##
## Sign Bias Test
## -----
##          t-value    prob sig
## Sign Bias      1.3840 0.16653
## Negative Sign Bias 1.4738 0.14070
## Positive Sign Bias 0.6549 0.51258
## Joint Effect      7.9278 0.04753 **
##
##
## Adjusted Pearson Goodness-of-Fit Test:
## -----
##   group statistic p-value(g-1)
## 1    20      33.12    0.02328
## 2    30      43.57    0.04032
## 3    40      45.07    0.23292
## 4    50      64.01    0.07348
##
##
## Elapsed time : 0.3108752

garch_coef <- coef(fit_garch)
garch_residuals <- residuals(fit_garch, standardize = TRUE)

# Estimar a densidade kernel
garch_densidade <- density(garch_residuals, kernel = "gaussian")

# Plotar a densidade kernel
plot(garch_densidade, main = "Estimativa de Densidade Kernel nos resíduos GARCH", col = "black", lwd=2)


hist(garch_residuals, freq = FALSE, add = TRUE, breaks = 100, col = "lightblue")

sigma_emp = sd(garch_residuals)
lines(density(rnorm(10000,0, sigma_emp)), col = "red", lwd=2)

lines(garch_densidade, col = "black", lwd=2)

```


Estimativa de Densidade Kernel nos resíduos GARCH



N = 1928 Bandwidth = 0.1876

```
library(forecast)
library(ggplot2)
library(zoo)
```

```
fcast_arima <- forecast(fit_arima, h = 10)
```

```
fcast_garch <- ugarchforecast(fit_garch, n.ahead = 10)
```

Gráfico comparando as duas projeções:

```
# Extrair previsões e intervalos
garch_mean <- fcast_arima$mean
garch_sigma <- sigma(fcast_garch)
garch_upper <- garch_mean + 1.96 * garch_sigma
garch_lower <- garch_mean - 1.96 * garch_sigma

# Extrair os últimos 30 pontos da série original
serie_final <- tail(log_ibov, 30)
datas_hist <- as.Date(time(serie_final))
ultima_data <- max(datas_hist)

# Datas da previsão
datas_prev <- seq(ultima_data + 1, by = "day", length.out = length(fcast_arima$mean))

# Criar data.frames
df_hist <- data.frame(Data = datas_hist, Valor = as.numeric(serie_final))
df_prev <- data.frame(
```

```

Data = datas_prev,
Media = as.numeric(fcast_arma$mean),
LimiteInferior = as.numeric(fcast_arma$lower[,2]), # 95%
LimiteSuperior = as.numeric(fcast_arma$upper[,2]) # 95%
)

# Adiciona o último ponto da série histórica como primeiro da previsão
ultimo_ponto <- data.frame(
Data = ultima_data,
Media = tail(df_hist$Valor, 1),
LimiteInferior = tail(df_hist$Valor, 1),
LimiteSuperior = tail(df_hist$Valor, 1)
)


df_prev <- rbind(ultimo_ponto, df_prev)

df_prev_garch <- data.frame(
Data = datas_prev,
Media = as.numeric(garch_mean),
LimiteInferior = as.numeric(garch_lower), # 95%
LimiteSuperior = as.numeric(garch_upper) # 95%
)


df_prev_garch <- rbind(ultimo_ponto, df_prev_garch)

# Plot com ggplot2
ggplot() +
  geom_line(data = df_hist, aes(x = Data, y = Valor), color = "black") +
  geom_line(data = df_prev, aes(x = Data, y = Media), color = "blue") +
  geom_ribbon(data = df_prev, aes(x = Data, ymin = LimiteInferior, ymax = LimiteSuperior),
  fill = "blue", alpha = 0.2) +
  coord_cartesian(ylim = c(11.75, 11.90)) +
  labs(title = "Previsão ARIMA com Intervalo de Confiança 95%",
  x = "Data", y = "Valor") +
  theme_minimal()

```



```
# Plot com ggplot2
ggplot() +
  geom_line(data = df_hist, aes(x = Data, y = Valor), color = "black") +
  geom_line(data = df_prev_garch, aes(x = Data, y = Media), color = "red") +
  geom_ribbon(data = df_prev_garch, aes(x = Data, ymin = LimiteInferior, ymax = LimiteSuperior),
    fill = "red", alpha = 0.2) +
  coord_cartesian(ylim = c(11.75, 11.90)) +
  labs(title = "Previsão ARIMA-GARCH com Intervalo de Confiança 95%",
    x = "Data", y = "Valor") +
  theme_minimal()
```



Outras possibilidades de modelos de volatilidade condicional

GARCH-M

- Modelos GARCH-M (GARCH-in-Mean) são uma extensão dos modelos GARCH tradicionais, muito utilizados em finanças para capturar a relação entre retorno esperado e risco (volatilidade).
- O modelo GARCH-M incorpora a variância condicional diretamente na equação da média do processo.
- A ideia é que o retorno esperado de um ativo pode depender do seu risco — medido pela variância ou desvio padrão condicional.
- A inclusão da variância na equação da média permite capturar o comportamento de investidores que exigem prêmios de risco maiores em períodos de maior incerteza. Isso torna o modelo mais realista em contextos de alta volatilidade.
- Um modelo GARCH-M(1,1) típico pode ser escrito como:

– Equação da média:

$$y_t = \mu + \lambda \cdot \sigma_t^2 + \epsilon_t$$

– Equação da variância condicional GARCH(1,1):

$$\sigma_t^2 = \omega + \alpha \cdot \epsilon_{t-1}^2 + \beta \cdot \sigma_{t-1}^2$$

– λ : coeficiente que mede o impacto do risco (variância) sobre o retorno esperado.

– Se $\lambda > 0$, isso sugere que maior risco está associado a maior retorno esperado, o que é consistente com a teoria financeira.

- Muito usado em modelagem de retornos financeiros, como ações, moedas e commodities, porque permite testar empiricamente a relação risco-retorno.
- Aplicações: precificação de ativos, gestão de risco e alocação de portfólio.

TGARCH(p,q,r)

- É um modelo GARCH com limiar, que permite capturar assimetria na volatilidade.
- Por exemplo, choques negativos tendem a aumentar mais a volatilidade do que choques positivos de mesma magnitude. Esse comportamento é chamado de efeito alavancagem.
- Modelos GARCH tradicionais não capturam assimetria, pois tratam choques positivos e negativos da mesma forma.
- Um modelo TGARCH(p,q,r) tem a seguinte especificação para a variância:

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 + \sum_{k=1}^r \gamma_k D_{(\epsilon_{t-k} \leq 0)} \cdot |\epsilon_{t-k}^2|$$

- γ mede o efeito assimétrico e D é uma função indicadora (dummy) se o choque foi negativo ou não. Se $\gamma > 0$ significa que choques negativos aumentam mais a vol do que choques positivos!
- Aplicações: modelagem de retornos de ações, precificação de opções, gestão de risco, VaR...

EGARCH(p,q,r)

- Modelos GARCH tradicionais impõem que os coeficientes sejam não negativos para garantir que a variância condicional seja positiva.
- Modelos EGARCH resolvem isso ao modelar o logaritmo da variância, o que garante positividade, sem aplicar restrições nos parâmetros.
- Além disso, o EGARCH também permite capturar assimetria (choques negativos aumentam mais a volatilidade do que choques positivos).
- Especificação de um EGARCH para a variância:

$$\ln(\sigma_t^2) = \omega + \sum_{i=1}^q \alpha_i [|u_{t-i}| - E(|u_{t-i}|)] + \sum_{j=1}^p \beta_j \ln(\sigma_{t-j}^2) + \sum_{k=1}^r \gamma_k u_{t-k}$$

onde $u_{t-i} = \epsilon_{t-i} / \sigma_{t-1}$ é o resíduo normalizado pela variância em cada período e γ_k é o coeficiente de assimetria.

- Vantagens do EGARCH: não exige restrições de coeficientes positivos, captura assimetria de forma direta e é mais adequado para séries com vol assimétrica e com leptocurtose.

PGARCH(p,q,d)

- O modelo PGARCH é uma generalização do modelo GARCH tradicional, proposto por Ding, Granger e Engle (1993) e permite maior flexibilidade na forma como a volatilidade reage aos choques.
- Modelos GARCH tradicionais assumem que a variância condicional depende do quadrado dos resíduos ϵ_t^2 .
- Como sabemos, nem sempre a vol é simétrica para choques positivos e negativos. A relação entre choques e vol pode não ser bem representada pelo quadrado dos resíduos.
- Especificação do modelo PGARCH:

$$\sigma_t^d = \omega + \sum_{j=1}^p \beta_j \sigma_{t-j}^d + \sum_{i=1}^q \alpha_i (|\epsilon_{t-i}| - \gamma_i \epsilon_{t-i})^d$$

onde $d > 0$ e pode ser estimado em vez de imposto.

- Com $d=1$, o modelo se torna uma estimação do desvio-padrão e com $d=2$, o modelo se torna um GARCH tradicional.
- Vantagens do PGARCH: permite ajustar o grau de sensibilidade da volatilidade aos choques e captura assimetria e leptocurtose de forma mais flexível. O GARCH é um caso especial.
- É mais usado para modelagem financeira em que a vol não tem comportamento linear (respostas assimétricas a choques)

EWMA

- O modelo EWMA (*Exponentially Weighted Moving Average*) é uma técnica simples e eficiente para modelar a volatilidade condicional.
- É amplamente utilizado em gestão de risco, especialmente em Value-at-Risk (VaR).
- O EWMA é uma média móvel que dá mais peso aos dados mais recentes, permitindo capturar mudanças na volatilidade de forma mais imediata.
- Especificação do EWMA: a variância condicional no tempo t :

$$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) \epsilon_{t-1}^2$$

onde $\lambda \in (0, 1)$ é o parâmetro de decaimento exponencial.

- Quanto maior λ , maior a memória do passado, mais lento é o ajuste da variância a novos choques.
- RiskMetrics/JP Morgan sugere $\lambda = 0,94$ para séries financeiras.
- Vantagens: simples de implementar, um único parâmetro para estimar, reage rapidamente ao curto prazo.
- Desvantagens: não modela assimetria, não captura efeitos de persistência adequadamente, assume que a média dos retornos é zero.
- É mais utilizado para monitoramento de risco em tempo real.