

Aula 10: Modelos VAR

Silvio Costa

2025-10-31

Introdução ao Vetor Autoregressivo (VAR)

- Modelos univariados são limitados!
- Um VAR permite modelar diversas variáveis simultaneamente.

Equação Estrutural do VAR:

$$AX_t = B_0 + \sum_{i=1}^p B_i X_{t-i} + B\epsilon_t$$

Onde:

- A : matriz de restrições (mxn)
- X_t : variáveis endógenas (nx1)
- B_0 : constantes (nx1)
- B_i : coeficientes (mxn)
- B : matriz diagonal (mxn)
- ϵ_t : choques (nx1) $\sim IID(0, I_n)$
 - No modelo estrutural, os choques são identificados, cada choque corresponde a uma alteração em sua respectiva variável. Por que isso é importante?

Equação da Forma Reduzida:

$$\begin{cases} X_t = A^{-1}B_0 + \sum_{i=1}^p B_i A^{-1}X_{t-i} + A^{-1}B\epsilon_t \\ X_t = \Phi_0 + \sum_{i=1}^p \Phi_i X_{t-i} + e_t \end{cases}$$

Exemplo:

$$\begin{cases} y_t = b_{10} - a_{12}z_t + b_{11}y_{t-1} + b_{12}z_{t-1} + \sigma_y\epsilon_{yt} \\ z_t = b_{20} - a_{21}y_t + b_{21}y_{t-1} + b_{22}z_{t-1} + \sigma_z\epsilon_{zt} \end{cases}$$

- As variáveis y_t e z_t são afetadas umas pelas outras e por suas defasagens. Nesse sentido, há um efeito feedback que atrapalha a estimação.
- O objetivo do VAR é desenvolver técnicas para resolver esse problema, encontrar a trajetória da variável de interesse para o choque estrutural.
- Hipóteses do modelo:
 - y_t e z_t são estacionários
 - $\epsilon_{yt} \sim RB(0, 1)$ e $\epsilon_{zt} \sim RB(0, 1)$
 - $\epsilon_{yt} \perp \epsilon_{zt} \rightarrow COV(\epsilon_{yt}, \epsilon_{zt}) = 0$

- De forma geral:
 - **Estacionaridade:** As séries temporais devem ser estacionárias ou transformadas para estacionaridade.
 - **Linearidade:** A relação entre as variáveis é linear.
 - **Erro Branco:** Os resíduos devem ser ruído branco, ou seja, não correlacionados e com média zero.
 - **Normalidade:** Os resíduos devem seguir uma distribuição normal.
- A Forma Reduzida permite estimar os modelos com erros não correlacionados com os regressores.
- Ainda haveria correlação contemporânea entre os erros, mas este não é um problema para a estimação do modelo VAR. um problema para estimarmos o VAR.
- Importante: A questão fundamental na modelagem VAR é se, a partir da forma reduzida, é possível recuperar os parâmetros que definem a forma estrutural.
- Por que isso é importante? somente por meio de análise de choques estruturais é possível identificar efeitos de políticas econômicas que tenham significado.
- É possível incluir variáveis exógenas no modelo VAR:

$$X_t = \Phi_0 + \sum_{i=1}^p \Phi_1 X_{t-i} + GZ_t + \epsilon_t$$

em que G é uma matriz de coeficientes ($n \times g$) e Z_t é um vetor de variáveis exógenas.

Especificação do Modelo VAR

- Dificilmente o número de diferenças necessárias para tornar estacionária uma variável do VAR é o mesmo das demais.
- A regra é utilizar tantas defasagens quantas forem necessárias para obter “ruídos brancos” em todas as variáveis endógenas.
- Bom senso e parcimônia devem ser utilizados nesse processo.
- Temos dois caminhos possíveis:
 1. Testes partindo de uma ordem p_{max} até rejeitar a hipótese nula
 2. Comparar os critérios de informação de diferentes especificações
- Na prática, usamos o segundo caminho, usando as versões multivariadas do AIC, BIC e HQ que seguem a estrutura:

$$Crit(m) = \ln |\hat{\Gamma}_0| + c_\tau \phi_m$$

em que:

$$\hat{\Gamma}_0 = \frac{1}{T} \sum_{t=1}^T \hat{\epsilon}_t \hat{\epsilon}_t'$$

- c_τ é uma sequência que depende do tamanho da amostra
- ϕ_m é uma função que penaliza VAR de grandes ordens
- Lütkepohl e Krätzig (2004) mostram que:

$$\hat{p}(BIC) \leq \hat{p}(HQ) \leq \hat{p}(AIC)$$

- Na prática, poucos lags não geram resíduos ruído-branco e muitos lags aumentam a variância dos coeficientes, tornando o modelo ineficiente.

Teste de Hipóteses no VAR

- A ideia é similar ao de modelos univariados. Ao invés de calcular a soma dos quadrados dos resíduos, agora usa-se o determinante da matriz de covariância dos resíduos do modelo restrito e do modelo irrestrito.
- Partindo da forma reduzida com variáveis exógenas:

$$X_t = \Phi_0 + \sum_{i=1}^p \Phi_1 X_{t-i} + GZ_t + \epsilon_t$$

- Podemos testar:
 - **Modelo restrito:** com menos parâmetros (ou restrições nos coeficientes).
 - **Modelo irrestrito:** mais geral, com mais flexibilidade.

$$LR = 2 (\ln L_{\text{irrestrito}} - \ln L_{\text{restrito}})$$

Onde:

- $L_{\text{irrestrito}}$: verossimilhança do modelo irrestrito
- L_{restrito} : verossimilhança do modelo restrito
 - O procedimento consiste em estimar ambos os modelos e calcular a razão de verossimilhança (LR).
 - Se LR for grande, as restrições prejudicam muito o ajuste. Logo, rejeita-se a H_0 : restrições não são compatíveis com os dados.
 - Se LR for pequeno, as restrições são razoáveis. Assim, não se rejeita H_0 : modelo restrito é aceitável.

Estacionaridade

- No mundo multivariado, continuaremos a analisar a estacionaridade das séries de tempo.
- O procedimento padrão consiste em verificar se os autovalores do sistema estão **dentro do círculo unitário**.
- Se houver variáveis não estacionárias, teremos que transformar o modelo de forma que os coeficientes sejam multiplicados por variáveis estacionárias.
- **IMPORTANTE:** em um modelo multivariado com variáveis não estacionárias, inferências sobre hipóteses conjuntas só poderão ser feitas se o modelo puder ser representado de tal forma que os coeficientes a serem testados passem a multiplicar variáveis estacionárias.
- Suponha que $y_t \sim I(1)$ e $z_t \sim I(1)$. Assuma um VAR(2) para essas variáveis e pegue a primeira equação que corresponde a y_t :

$$y_t = \phi_{11,1}y_{t-1} + \phi_{12,1}z_{t-1} + \phi_{11,2}y_{t-2} + \phi_{12,2}z_{t-2} + e_{yt}$$

- A estratégia é adicionar e subtrair termos para transformar:

$$y_t = (\phi_{11,1} + \phi_{11,2})y_{t-1} + (\phi_{12,1} + \phi_{12,2})z_{t-1} - \phi_{11,2}\Delta y_{t-1} - \phi_{12,2}\Delta z_{t-1} + e_{yt}$$

- Repare que Δy_{t-1} e Δz_{t-1} são estacionários. Logo, é possível fazer inferência sobre os coeficientes $\phi_{11,2}$ e $\phi_{12,2}$

Diagnóstico dos Resíduos

Teste Ljung-Box:

- Mesma lógica do caso univariado, testamos a autocorrelação amostral:
- $H_0: E(\epsilon_t \epsilon_{t-j}) = 0, \forall j = 1, 2, \dots, J \text{ e } J > p$
- Estatística do teste:

$$Q = T \sum_{j=1}^J \text{tr}(\hat{\Gamma}_j \hat{\Gamma}_0^{-1} \hat{\Gamma}_j \hat{\Gamma}_0^{-1}) \sim \chi_{n^2(J-p)}^2$$

Teste Breusch-Godfrey:

- Testa a autocorrelação dos resíduos do modelo:

$$\hat{e}_t = \Theta_1 \hat{e}_{t-1} + \Theta_2 \hat{e}_{t-2} + \dots + \Theta_h \hat{e}_{t-h} + u_t$$

- $H_0: \Theta_1 = \Theta_2 = \dots = \Theta_h = 0$

Teste Normalidade (Jarque-Bera para o caso multivariado):

- Testa assimetria e curtose dos resíduos compatíveis com uma distribuição normal multivariada.

Previsão com VAR

Equação de Previsão:

$$E(X_{t+h}|I_t) = X_{t+h} = \Phi_1 X_{t+h-1} + \Phi_2 X_{t+h-2} + \dots + \Phi_p X_{t+h-p}$$

- **Nota:** Se o processo for estacionário, a incerteza sobre a previsão é limitada.
- Erros de previsão mais distantes têm limite bem definido.
- Na presença de variáveis exógenas, o procedimento é projetar a evolução dessas variáveis e realizar a previsão do VAR condicional a essa projeção.

Exemplo prático no R:

Primeiro vamos montar nossa base de dados com inflação, atividade e juros.

```
#install.packages("vars")
library(rbc)
library(tseries)
```

```
## Registered S3 method overwritten by 'quantmod':
##   method      from
##   as.zoo.data.frame zoo
```

```
library(ggplot2)
library(vars)
```

```
## Loading required package: MASS
```

```
## Loading required package: strucchange
```

```

## Loading required package: zoo

##
## Attaching package: 'zoo'

## The following objects are masked from 'package:base':
##
##      as.Date, as.Date.numeric

## Loading required package: sandwich

## Loading required package: urca

## Loading required package: lmtest

ipca_table = get_series(433, start_date = '2000-01-01')
ipcats = ts( ipca_table$`433`, start = c( 2000, 1 ), frequency = 12 )      # IPCA

ibc_table <- get_series(24364, start_date = '2003-01-01')
idxibcts <- ts(ibc_table$`24364`, start = c(2003, 1), frequency = 12)      # IBC-BR


ibcts <- diff(log(idxibcts))

selic_table <- get_series(4189, start_date = '2000-01-01')
selicts <- ts(selic_table$`4189`, start = c(2000, 1), frequency = 12)      # Selic

# Plotando cada série temporal individualmente
par(mfrow = c(1,3)) # Configura a área de plotagem para 1 linha e 3 colunas

plot(ipcats, main = "IPCA", col = "blue", lwd = 2)
plot(ibcts, main = "IBC", col = "red", lwd = 2)
plot(selicts, main = "Selic", col = "green", lwd = 2)

```



```
dbvar <- ts.intersect( ipcats, ibcts, selicts)

dbvar <- ts(dbvar, start = start(dbvar), frequency = 12)
```

Agora vamos selecionar a ordem do VAR a partir de critérios de informação:

```
# Selecionando a ordem do modelo VAR
var_order <- VARselect(dbvar, lag.max = 10, type = "const")
print(var_order)
```

```
## $selection
## AIC(n)  HQ(n)  SC(n) FPE(n)
##      5      3      2      5
##
## $criteria
##           1           2           3           4           5
## AIC(n) -1.359119e+01 -1.459665e+01 -1.471886e+01 -1.470461e+01 -1.479884e+01
## HQ(n)  -1.352532e+01 -1.448137e+01 -1.455417e+01 -1.449051e+01 -1.453533e+01
## SC(n)  -1.342731e+01 -1.430985e+01 -1.430915e+01 -1.417198e+01 -1.414330e+01
## FPE(n)  1.251476e-06  4.579009e-07  4.052551e-07  4.111262e-07  3.742359e-07
##           6           7           8           9          10
## AIC(n) -1.477891e+01 -1.474612e+01 -1.471340e+01 -1.473453e+01 -1.473549e+01
## HQ(n)  -1.446600e+01 -1.438380e+01 -1.430167e+01 -1.427339e+01 -1.422494e+01
## SC(n)  -1.400045e+01 -1.384475e+01 -1.368911e+01 -1.358733e+01 -1.346537e+01
## FPE(n)  3.818877e-07  3.947860e-07  4.081511e-07  3.999034e-07  3.998762e-07
```

Um modelo bem ajustado aos dados significa:

1. Parâmetros estimados são estatisticamente significantes (só vale a pena aumentar a ordem do modelo para melhorar o ajuste se os parâmetros acrescentados forem significantes! caso contrário, melhor escolher um modelo mais parcimonioso)
 2. Resíduos não devem apresentar autocorrelação serial, correlação cruzada ou heterocedasticidade condicional.
 3. O modelo é estável ou estacionário (média incondicional do VAR existe). Para isso, verificamos os autovalores associados à matriz conjunta dos coeficientes defasados (de maneira similar ao caso univariado). Queremos que todos os autovalores (raízes) sejam menores do que 1.
 - Não confunda a estacionariedade do modelo com a estacionariedade individual das séries!
 4. Resíduos não violam a hipótese de distribuição Normal.
-

- **Sempre teste vários modelos VAR com ordens diferentes, eventualmente imponha restrições nos lags ou acrescente variáveis exógenas. O objetivo é obter resíduos que se pareçam com um ruído branco.**

Escolhida uma ordem para o VAR, vamos estimar os coeficientes:

```
#minha_selecao = var_order$selection["AIC(n)"]
minha_selecao = 5;
# o modelo com 5 lags e 3 variáveis tem 15 raízes.
# são estimados 18 coeficientes (15 dos lags + 3 interceptos)
# é um modelo complexo que, como veremos, falhará na hipótese de resíduos normalmente distribuídos
# na prática, queremos o melhor ajuste possível com o modelo mais parcimonioso (menor ordem)

# Estimando o modelo VAR
var_model <- VAR(dbvar, p = minha_selecao, type = "const")
summary(var_model)

##
## VAR Estimation Results:
## =====
## Endogenous variables: ipcats, ibcts, selicts
## Deterministic variables: const
## Sample size: 266
## Log Likelihood: 843.451
## Roots of the characteristic polynomial:
## 0.9263 0.8113 0.8113 0.727 0.727 0.6896 0.6896 0.6722 0.6722 0.6451 0.6451 0.6154 0.6154 0.5163 0.5163
## Call:
## VAR(y = dbvar, p = minha_selecao, type = "const")
##
##
## Estimation results for equation ipcats:
## =====
## ipcats = ipcats.l1 + ibcts.l1 + selicts.l1 + ipcats.l2 + ibcts.l2 + selicts.l2 + ipcats.l3 + ibcts.l3
##
##           Estimate Std. Error t value Pr(>|t|)
## ipcats.l1  0.496523   0.063482   7.821 1.46e-13 ***
## ibcts.l1    2.624854   1.534034   1.711  0.0883 .
## selicts.l1  0.041082   0.077792   0.528  0.5979
## ipcats.l2   0.050922   0.070804   0.719  0.4727
## ibcts.l2   -1.593554   1.581090  -1.008  0.3145
## selicts.l2  0.001187   0.142828   0.008  0.9934
## ipcats.l3  -0.024797   0.072054  -0.344  0.7310
```

```

## ibcts.l3      1.598379    1.558028    1.026    0.3059
## selicts.l3   -0.004125    0.146431   -0.028    0.9776
## ipcats.l4    -0.020303    0.073307   -0.277    0.7820
## ibcts.l4     -1.481293    1.563002   -0.948    0.3442
## selicts.l4   -0.052732    0.139625   -0.378    0.7060
## ipcats.l5    -0.076015    0.065893   -1.154    0.2498
## ibcts.l5      0.235945    1.505643    0.157    0.8756
## selicts.l5    0.014860    0.072622    0.205    0.8380
## const        0.263200    0.059410    4.430 1.41e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
## Residual standard error: 0.2742 on 250 degrees of freedom
## Multiple R-Squared: 0.3311, Adjusted R-squared: 0.2909
## F-statistic: 8.249 on 15 and 250 DF, p-value: 3.464e-15
##
##
## Estimation results for equation ibcts:
## =====
## ibcts = ipcats.l1 + ibcts.l1 + selicts.l1 + ipcats.l2 + ibcts.l2 + selicts.l2 + ipcats.l3 + ibcts.l3
##
##              Estimate Std. Error t value Pr(>|t|)
## ipcats.l1   -0.0017825  0.0026057   -0.684 0.494558
## ibcts.l1      0.2184546  0.0629662    3.469 0.000614 ***
## selicts.l1    0.0013717  0.0031930    0.430 0.667865
## ipcats.l2     0.0055309  0.0029062    1.903 0.058174 .
## ibcts.l2     -0.1407900  0.0648976   -2.169 0.030994 *
## selicts.l2   -0.0011654  0.0058625   -0.199 0.842589
## ipcats.l3    -0.0097122  0.0029575   -3.284 0.001170 **
## ibcts.l3     -0.0883273  0.0639510   -1.381 0.168460
## selicts.l3    0.0009123  0.0060104    0.152 0.879473
## ipcats.l4     0.0008828  0.0030090    0.293 0.769477
## ibcts.l4      0.0638270  0.0641552    0.995 0.320754
## selicts.l4   -0.0047937  0.0057311   -0.836 0.403701
## ipcats.l5    -0.0018855  0.0027047   -0.697 0.486364
## ibcts.l5     -0.1225172  0.0618008   -1.982 0.048523 *
## selicts.l5    0.0038122  0.0029808    1.279 0.202124
## const        0.0033848  0.0024386    1.388 0.166364
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
## Residual standard error: 0.01126 on 250 degrees of freedom
## Multiple R-Squared: 0.1364, Adjusted R-squared: 0.08454
## F-statistic: 2.632 on 15 and 250 DF, p-value: 0.001038
##
##
## Estimation results for equation selicts:
## =====
## selicts = ipcats.l1 + ibcts.l1 + selicts.l1 + ipcats.l2 + ibcts.l2 + selicts.l2 + ipcats.l3 + ibcts.l3
##
##              Estimate Std. Error t value Pr(>|t|)
## ipcats.l1     0.020196   0.049465    0.408 0.683414

```

```
## ibcts.l1      2.494124    1.195322    2.087 0.037940 *
## selicts.l1    1.583282    0.060615   26.120 < 2e-16 ***
## ipcats.l2     0.171910    0.055170    3.116 0.002047 **
## ibcts.l2      0.712757    1.231988    0.579 0.563419
## selicts.l2   -0.438929    0.111291   -3.944 0.000104 ***
## ipcats.l3     0.021446    0.056145    0.382 0.702803
## ibcts.l3      2.197791    1.214018    1.810 0.071443 .
## selicts.l3    0.143496    0.114099    1.258 0.209695
## ipcats.l4    -0.021573    0.057121   -0.378 0.705991
## ibcts.l4     -0.015052    1.217893   -0.012 0.990149
## selicts.l4   -0.575369    0.108796   -5.289 2.69e-07 ***
## ipcats.l5    -0.005908    0.051344   -0.115 0.908487
## ibcts.l5      0.927707    1.173199    0.791 0.429839
## selicts.l5    0.274952    0.056587    4.859 2.08e-06 ***
## const        0.037029    0.046293    0.800 0.424534
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
## Residual standard error: 0.2137 on 250 degrees of freedom
## Multiple R-Squared:  0.9976, Adjusted R-squared:  0.9974
## F-statistic: 6869 on 15 and 250 DF, p-value: < 2.2e-16
##
##
## Covariance matrix of residuals:
##          ipcats    ibcts    selicts
## ipcats  0.0752031 0.0003326 0.0052363
## ibcts   0.0003326 0.0001267 0.0001239
## selicts 0.0052363 0.0001239 0.0456600
##
## Correlation matrix of residuals:
##          ipcats    ibcts    selicts
## ipcats  1.00000 0.1078 0.08936
## ibcts   0.10777 1.0000 0.05150
## selicts 0.08936 0.0515 1.00000
```

Outra forma de apresentar os resultados no R é usando o pacote stargazer:

```
library(stargazer)
```

```
##
```

```
## Please cite as:
```

```
## Hlavac, Marek (2022). stargazer: Well-Formatted Regression and Summary Statistics Tables.
```

```
## R package version 5.2.3. https://CRAN.R-project.org/package=stargazer
```

```
stargazer::stargazer( var_model$varresult, type = "text", style = "aer", title = "Meu primeiro VAR", co
```

```
##
```

```
## Meu primeiro VAR
```

```
## =====
##
##              y
##              Atividade      Juros
##              (1)          (2)      (3)
## -----
```

## ipcats.l1	0.497***	-0.002	0.020
##	(0.063)	(0.003)	(0.049)
##			
## ibcts.l1	2.625*	0.218***	2.494**
##	(1.534)	(0.063)	(1.195)
##			
## selicts.l1	0.041	0.001	1.583***
##	(0.078)	(0.003)	(0.061)
##			
## ipcats.l2	0.051	0.006*	0.172***
##	(0.071)	(0.003)	(0.055)
##			
## ibcts.l2	-1.594	-0.141**	0.713
##	(1.581)	(0.065)	(1.232)
##			
## selicts.l2	0.001	-0.001	-0.439***
##	(0.143)	(0.006)	(0.111)
##			
## ipcats.l3	-0.025	-0.010***	0.021
##	(0.072)	(0.003)	(0.056)
##			
## ibcts.l3	1.598	-0.088	2.198*
##	(1.558)	(0.064)	(1.214)
##			
## selicts.l3	-0.004	0.001	0.143
##	(0.146)	(0.006)	(0.114)
##			
## ipcats.l4	-0.020	0.001	-0.022
##	(0.073)	(0.003)	(0.057)
##			
## ibcts.l4	-1.481	0.064	-0.015
##	(1.563)	(0.064)	(1.218)
##			
## selicts.l4	-0.053	-0.005	-0.575***
##	(0.140)	(0.006)	(0.109)
##			
## ipcats.l5	-0.076	-0.002	-0.006
##	(0.066)	(0.003)	(0.051)
##			
## ibcts.l5	0.236	-0.123**	0.928
##	(1.506)	(0.062)	(1.173)
##			
## selicts.l5	0.015	0.004	0.275***
##	(0.073)	(0.003)	(0.057)
##			
## const	0.263***	0.003	0.037
##	(0.059)	(0.002)	(0.046)
##			
## Observations	266	266	266
## R2	0.331	0.136	0.998
## Adjusted R2	0.291	0.085	0.997
## Residual Std. Error (df = 250)	0.274	0.011	0.214
## F Statistic (df = 15; 250)	8.249***	2.632***	6,868.916***
##	-----		


```
## Notes:          ***Significant at the 1 percent level.
##                **Significant at the 5 percent level.
##                *Significant at the 10 percent level.
```

Avaliando os resíduos do VAR:

```
# Plotando as séries individuais dos resíduos
resids = residuals(var_model)
resids = ts(resids, start=start(dbvar), frequency = 12)

par(mfrow = c(1, ncol(resids))) # Configura o layout para múltiplos gráficos

for (i in 1:ncol(resids)) {
  plot.ts(resids[, i], main = paste("Resíduo da Série", colnames(resids)[i]))
}
```



Diagnóstico dos Resíduos: o que significam esses resultados?

```
# Ljung-Box test, also known as a portmanteau test
serial.test(var_model, lags.pt = 16, type = "PT.asymptotic")
```

```
##
## Portmanteau Test (asymptotic)
##
## data: Residuals of VAR object var_model
## Chi-squared = 109.77, df = 99, p-value = 0.2158
```

```
# Breusch-Godfrey test
serial.test(var_model, lags.bg = 10, type = "BG")
```

```
##
## Breusch-Godfrey LM test
```

```

##
## data: Residuals of VAR object var_model
## Chi-squared = 168.01, df = 90, p-value = 1.183e-06
# Jarque-Bera
normality.test(var_model,multivariate.only = TRUE)

## $JB
##
## JB-Test (multivariate)
##
## data: Residuals of VAR object var_model
## Chi-squared = 3294.4, df = 6, p-value < 2.2e-16
##
##
## $Skewness
##
## Skewness only (multivariate)
##
## data: Residuals of VAR object var_model
## Chi-squared = 228.75, df = 3, p-value < 2.2e-16
##
##
## $Kurtosis
##
## Kurtosis only (multivariate)
##
## data: Residuals of VAR object var_model
## Chi-squared = 3065.7, df = 3, p-value < 2.2e-16
# Heteroscedasticidade
arch_test <- arch.test( var_model, lags.multi = 12, multivariate.only = TRUE)
print(arch_test)

##
## ARCH (multivariate)
##
## data: Residuals of VAR object var_model
## Chi-squared = 707.49, df = 432, p-value = 1.221e-15
## $arch.mul
##
## ARCH (multivariate)
##
## data: Residuals of VAR object var_model
## Chi-squared = 707.49, df = 432, p-value = 1.221e-15
Agora calculamos os autovalores do polinômio característico (repare que as raízes também são mostradas automaticamente no resultado de estimação VAR() acima)
# Autovalores do VAR
eigenvalues <- roots(var_model)
print(eigenvalues)

## [1] 0.9263100 0.8112962 0.8112962 0.7269796 0.7269796 0.6896037 0.6896037
## [8] 0.6721841 0.6721841 0.6451495 0.6451495 0.6154203 0.6154203 0.5163304
## [15] 0.5163304

```


Mas aqui queremos mostrar graficamente as raízes e o círculo unitário:

```
# Plotar o círculo unitário
plot(0, 0, type = "n", xlab = "Parte Real", ylab = "Parte Imaginária",
     xlim = c(-1.5, 1.5), ylim = c(-1.5, 1.5), asp = 1)
symbols(0, 0, circles = 1, inches = FALSE, add = TRUE)

# Plotar as raízes
points(Re(eigenvalues), Im(eigenvalues), col = "red", pch = 19)

# Adicionar título
title("Raízes do Polinômio Característico no Círculo Unitário")
```




Raízes do Polinômio Característico no Círculo Unitário



O VAR é estacionário. Outro testes de estabilidade pode verificar o que acontece com o modelo quando choques aleatórios são simulados:

```
#For details, please refer to documentation efp.
stability_test <- stability( var_model, type = "OLS-CUSUM", dynamic = TRUE) # Ploberger and Krämer (199)
plot(stability_test)
```

Empirical fluctuation process



Podemos testar quebra estrutural nos parâmetros:


```
# Teste de quebra estrutural  
strucchange::sctest( var_model )
```

```
##  
## M-fluctuation test  
##  
## data: var_model  
## f(efp) = 1.7524, p-value = 0.1869
```


Agora podemos fazer uma previsão com o modelo VAR escolhido:

```
# Previsão com o modelo VAR  
forecast <- predict(var_model, n.ahead = 12, ci= 0.95)  
  
plot(forecast)
```


Forecast of series ipcats



Forecast of series ibcts



Forecast of series selicts



Valores previstos:

```
print(forecast)
```

```
## $ipcats
##          fcst      lower      upper      CI
## [1,] 0.2236205 -0.3138642 0.7611051 0.5374846
## [2,] 0.3335909 -0.2730513 0.9402332 0.6066423
## [3,] 0.4205768 -0.2085556 1.0497091 0.6291323
## [4,] 0.4497019 -0.1905900 1.0899937 0.6402919
## [5,] 0.4768660 -0.1667369 1.1204690 0.6436029
## [6,] 0.4660837 -0.1793621 1.1115294 0.6454457
## [7,] 0.4462109 -0.2010717 1.0934936 0.6472826
## [8,] 0.4339463 -0.2141674 1.0820600 0.6481137
## [9,] 0.4258950 -0.2225836 1.0743737 0.6484787
## [10,] 0.4254975 -0.2231512 1.0741463 0.6486488
## [11,] 0.4276649 -0.2210408 1.0763707 0.6487057
## [12,] 0.4335976 -0.2151497 1.0823450 0.6487473
##
## $ibcts
##          fcst      lower      upper      CI
## [1,] 0.003344960 -0.01871670 0.02540662 0.02206166
## [2,] 0.002767431 -0.01982424 0.02535911 0.02259167
## [3,] 0.005605616 -0.01718368 0.02839491 0.02278930
## [4,] 0.004572972 -0.01864246 0.02778840 0.02321543
## [5,] 0.003501249 -0.01983343 0.02683593 0.02333468
## [6,] 0.002339510 -0.02116197 0.02584099 0.02350148
## [7,] 0.002538226 -0.02102508 0.02610153 0.02356331
## [8,] 0.002043296 -0.02155769 0.02564428 0.02360099
## [9,] 0.002057015 -0.02155717 0.02567120 0.02361419
## [10,] 0.002161585 -0.02145640 0.02577957 0.02361798
```

```

## [11,] 0.002362255 -0.02125881 0.02598332 0.02362107
## [12,] 0.002338490 -0.02128282 0.02595980 0.02362131
##
## $selicts
##      fcst      lower      upper      CI
## [1,] 14.76768 14.348866 15.18648 0.4188089
## [2,] 14.50968 13.720121 15.29925 0.7895641
## [3,] 14.19805 13.000842 15.39525 1.1972064
## [4,] 13.88056 12.165292 15.59582 1.7152649
## [5,] 13.57345 11.337988 15.80891 2.2354620
## [6,] 13.29920 10.539368 16.05904 2.7598340
## [7,] 13.05864  9.774146 16.34314 3.2844965
## [8,] 12.84821  9.075995 16.62043 3.7722154
## [9,] 12.66144  8.440055 16.88282 4.2213817
## [10,] 12.49344  7.864030 17.12284 4.6294060
## [11,] 12.33917  7.349946 17.32840 4.9892276
## [12,] 12.19779  6.892317 17.50326 5.3054690

```